Pontificia Universidad
JAVERIANA
Colombia

Tópicos Avanzados en Analítica

Maestría en Analítica para la Inteligencia de Negocios

Sergio Alberto Mora Pardo - H2 2024

Deep Learning

Intro Deep Learning

Biological Neurons

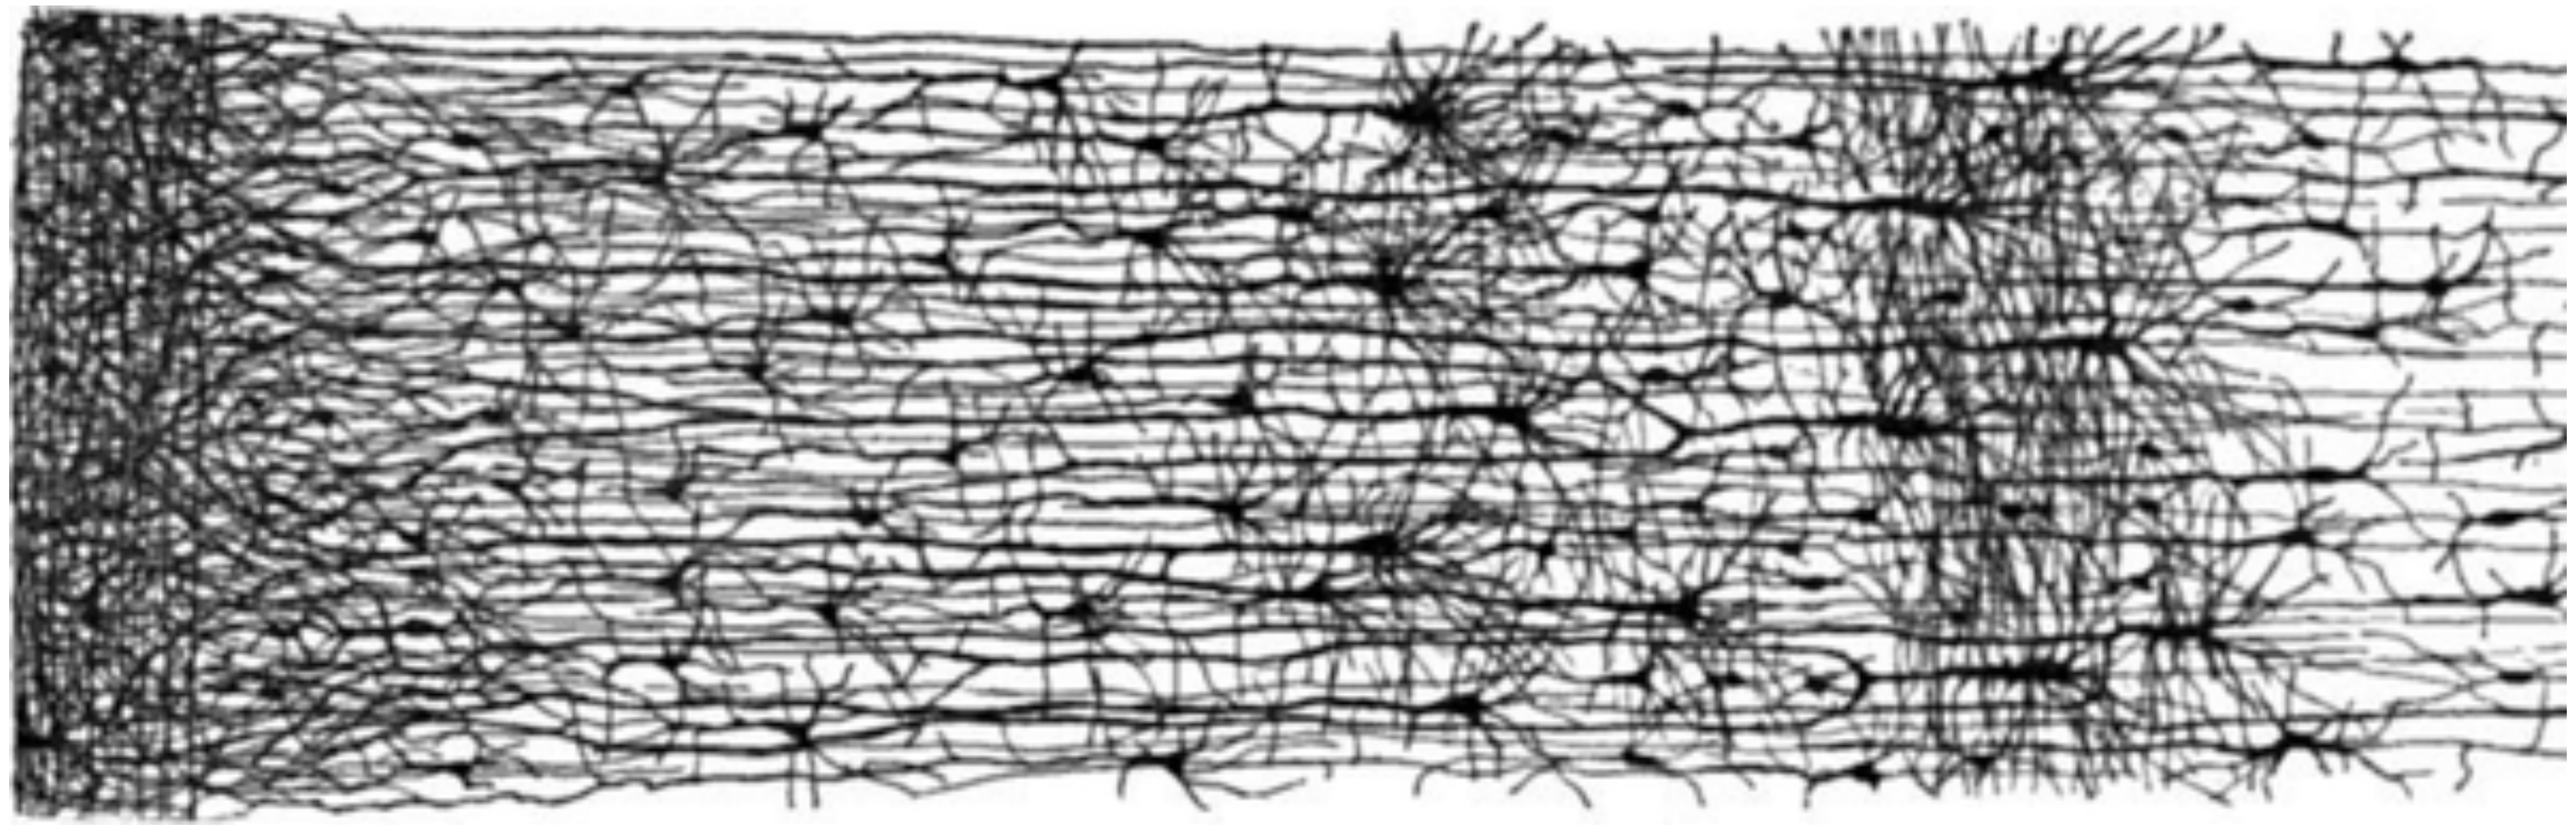

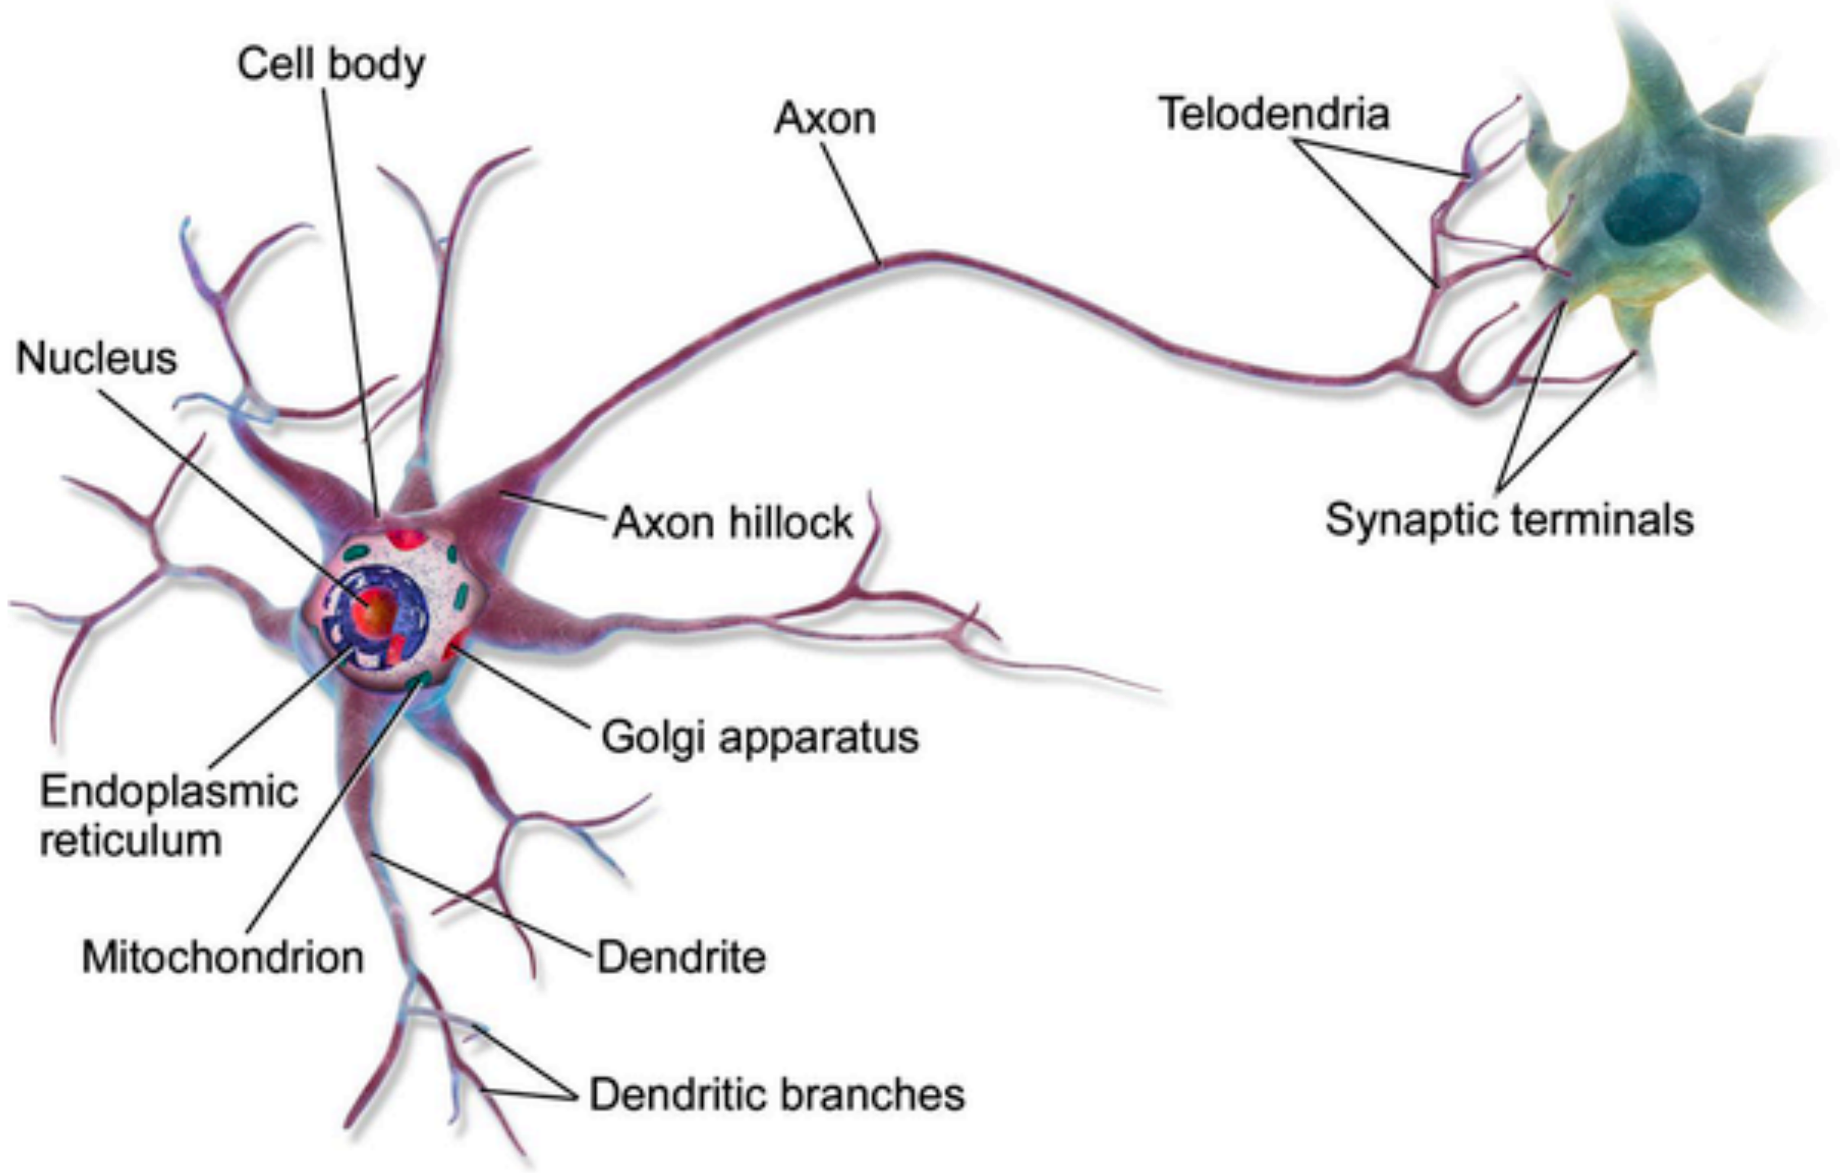

Intro Deep Learning

Biological Neurons

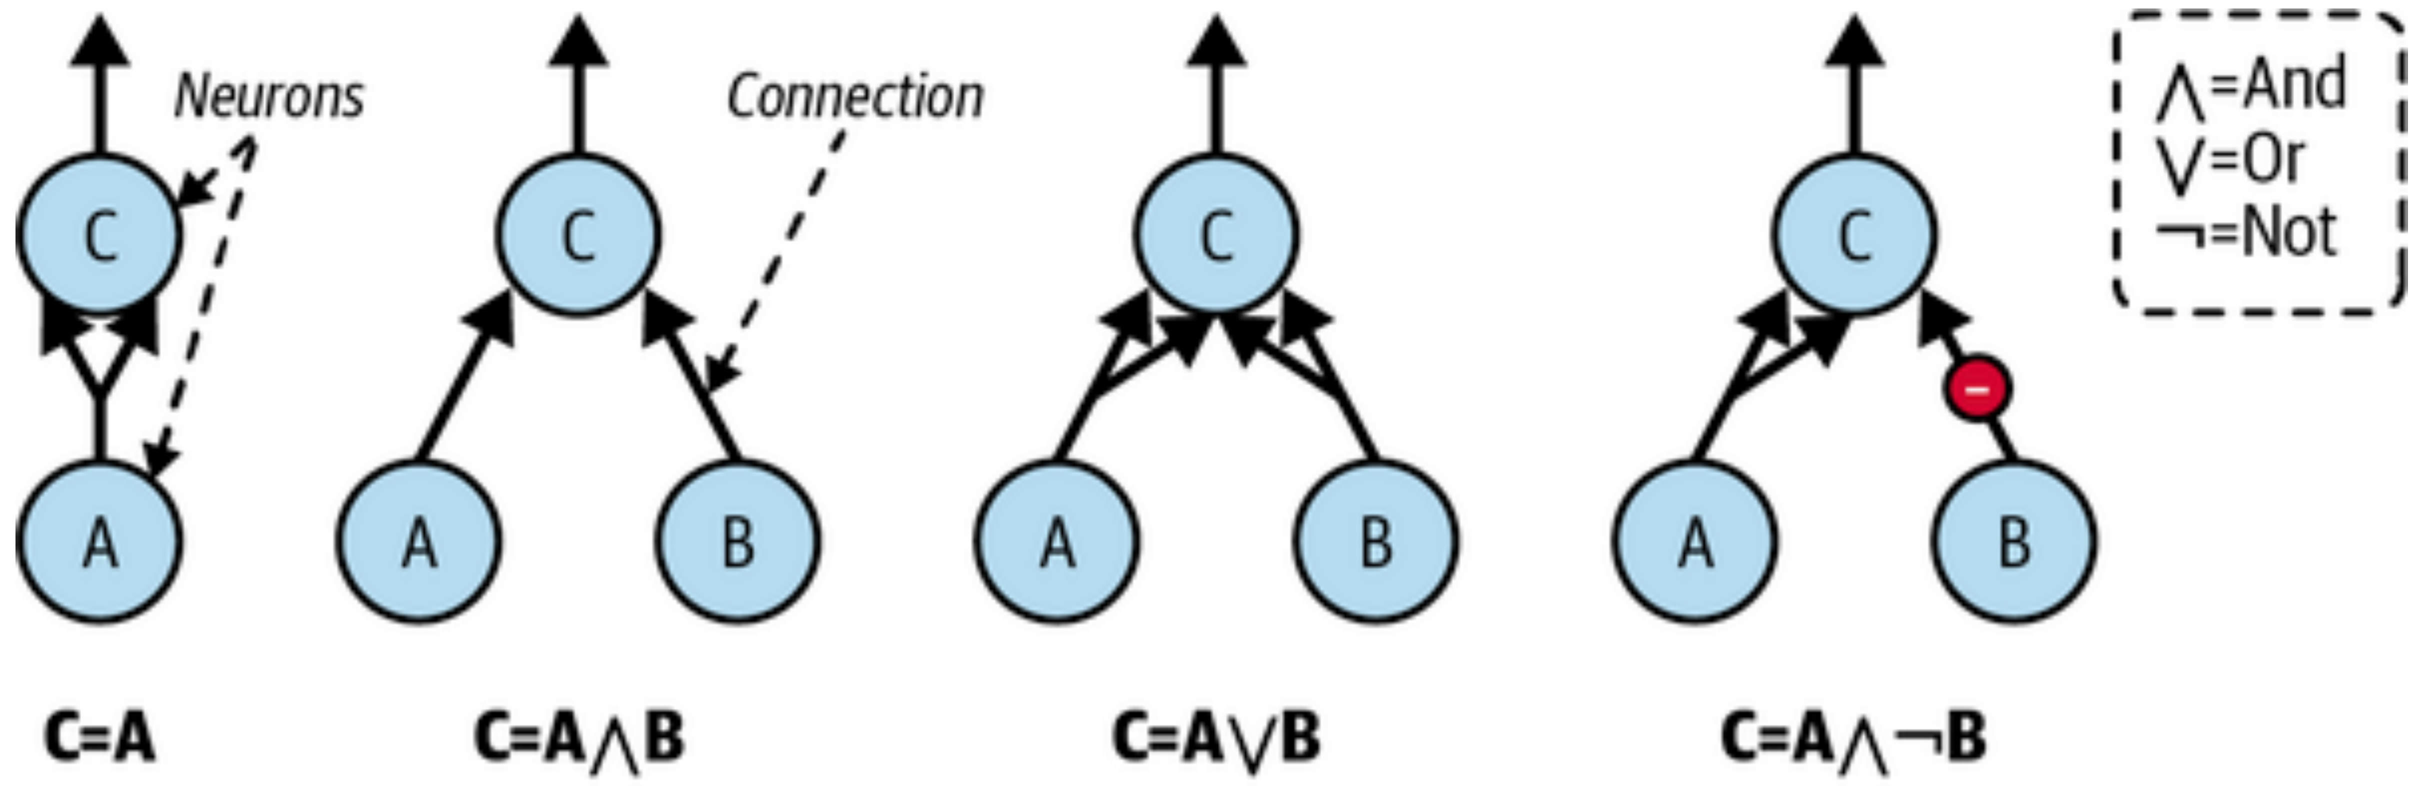

ANN que realiza cálculos lógicos simples

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Las entradas y salidas son números

Luego aplica una función escalonada al resultado

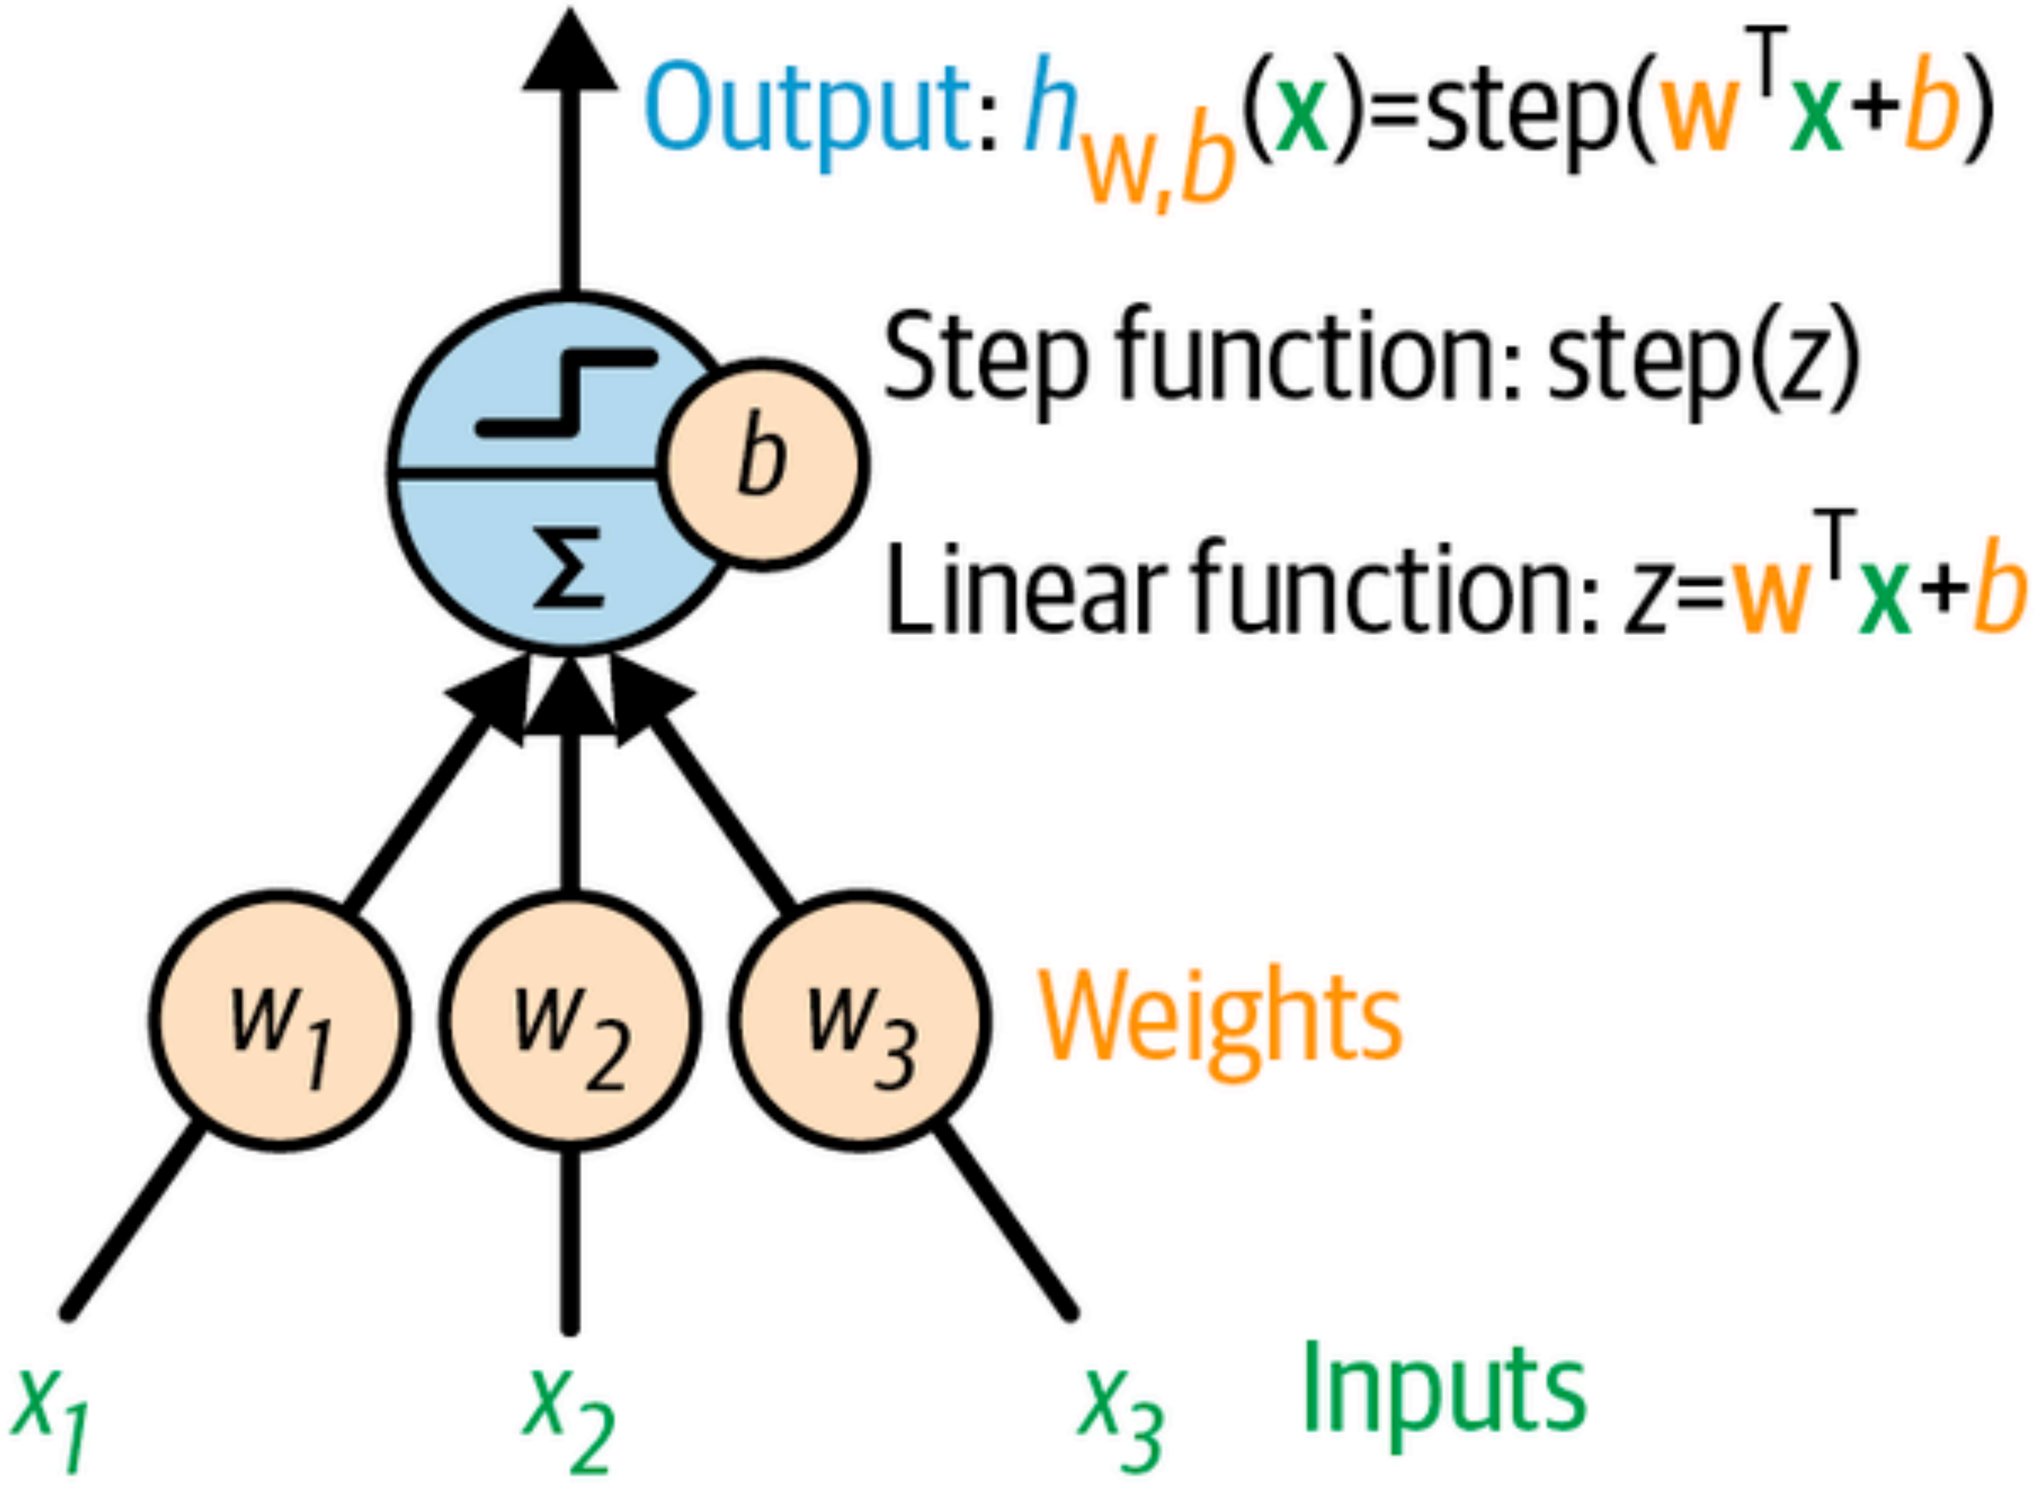

1957 por Frank Rosenblatt

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Las entradas y salidas son números

↓

Luego aplica una función escalonada al resultado

$z = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b$

$Z = w^T x + b$.

Función escalonada (h):

$h_w(x) = step(z)$

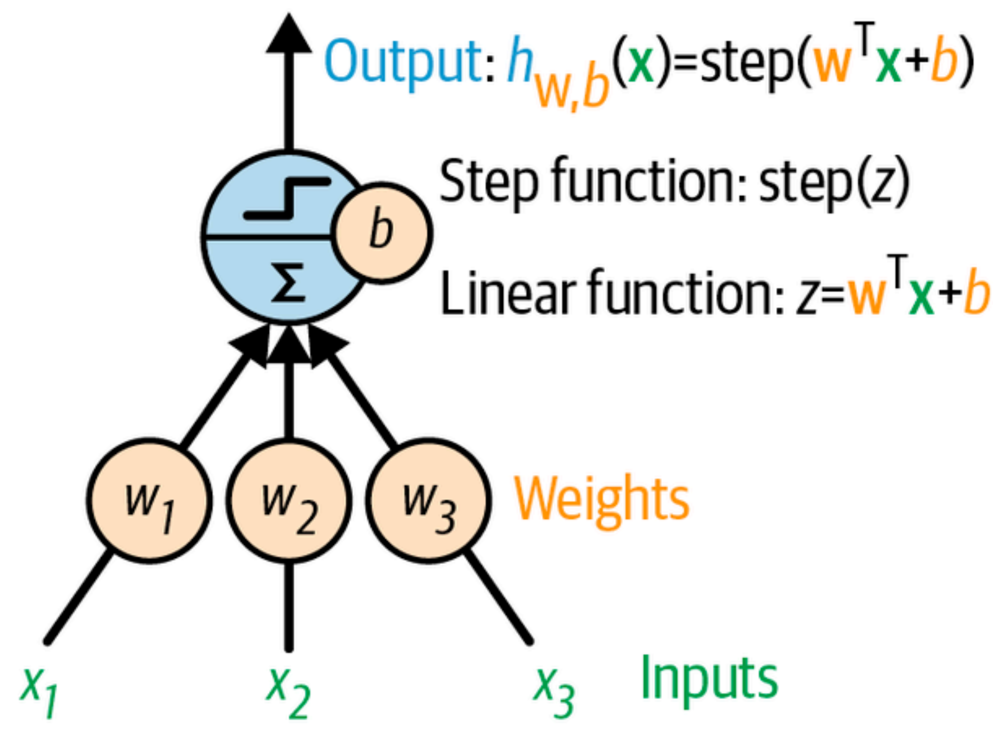

$$\text{heaviside}(z) = \begin{cases} 0 & \text{if } z < 0 \\ 1 & \text{if } z \geq 0 \end{cases} \qquad \text{sgn}(z) = \begin{cases} -1 & \text{if } z < 0 \\ 0 & \text{if } z = 0 \\ +1 & \text{if } z > 0 \end{cases}$$

1957 por Frank Rosenblatt

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Las entradas y salidas son números

Luego aplica una función escalonada al resultado

Arquitectura de un perceptrón

- 2 neuronas de entrada

- 3 neuronas de salida

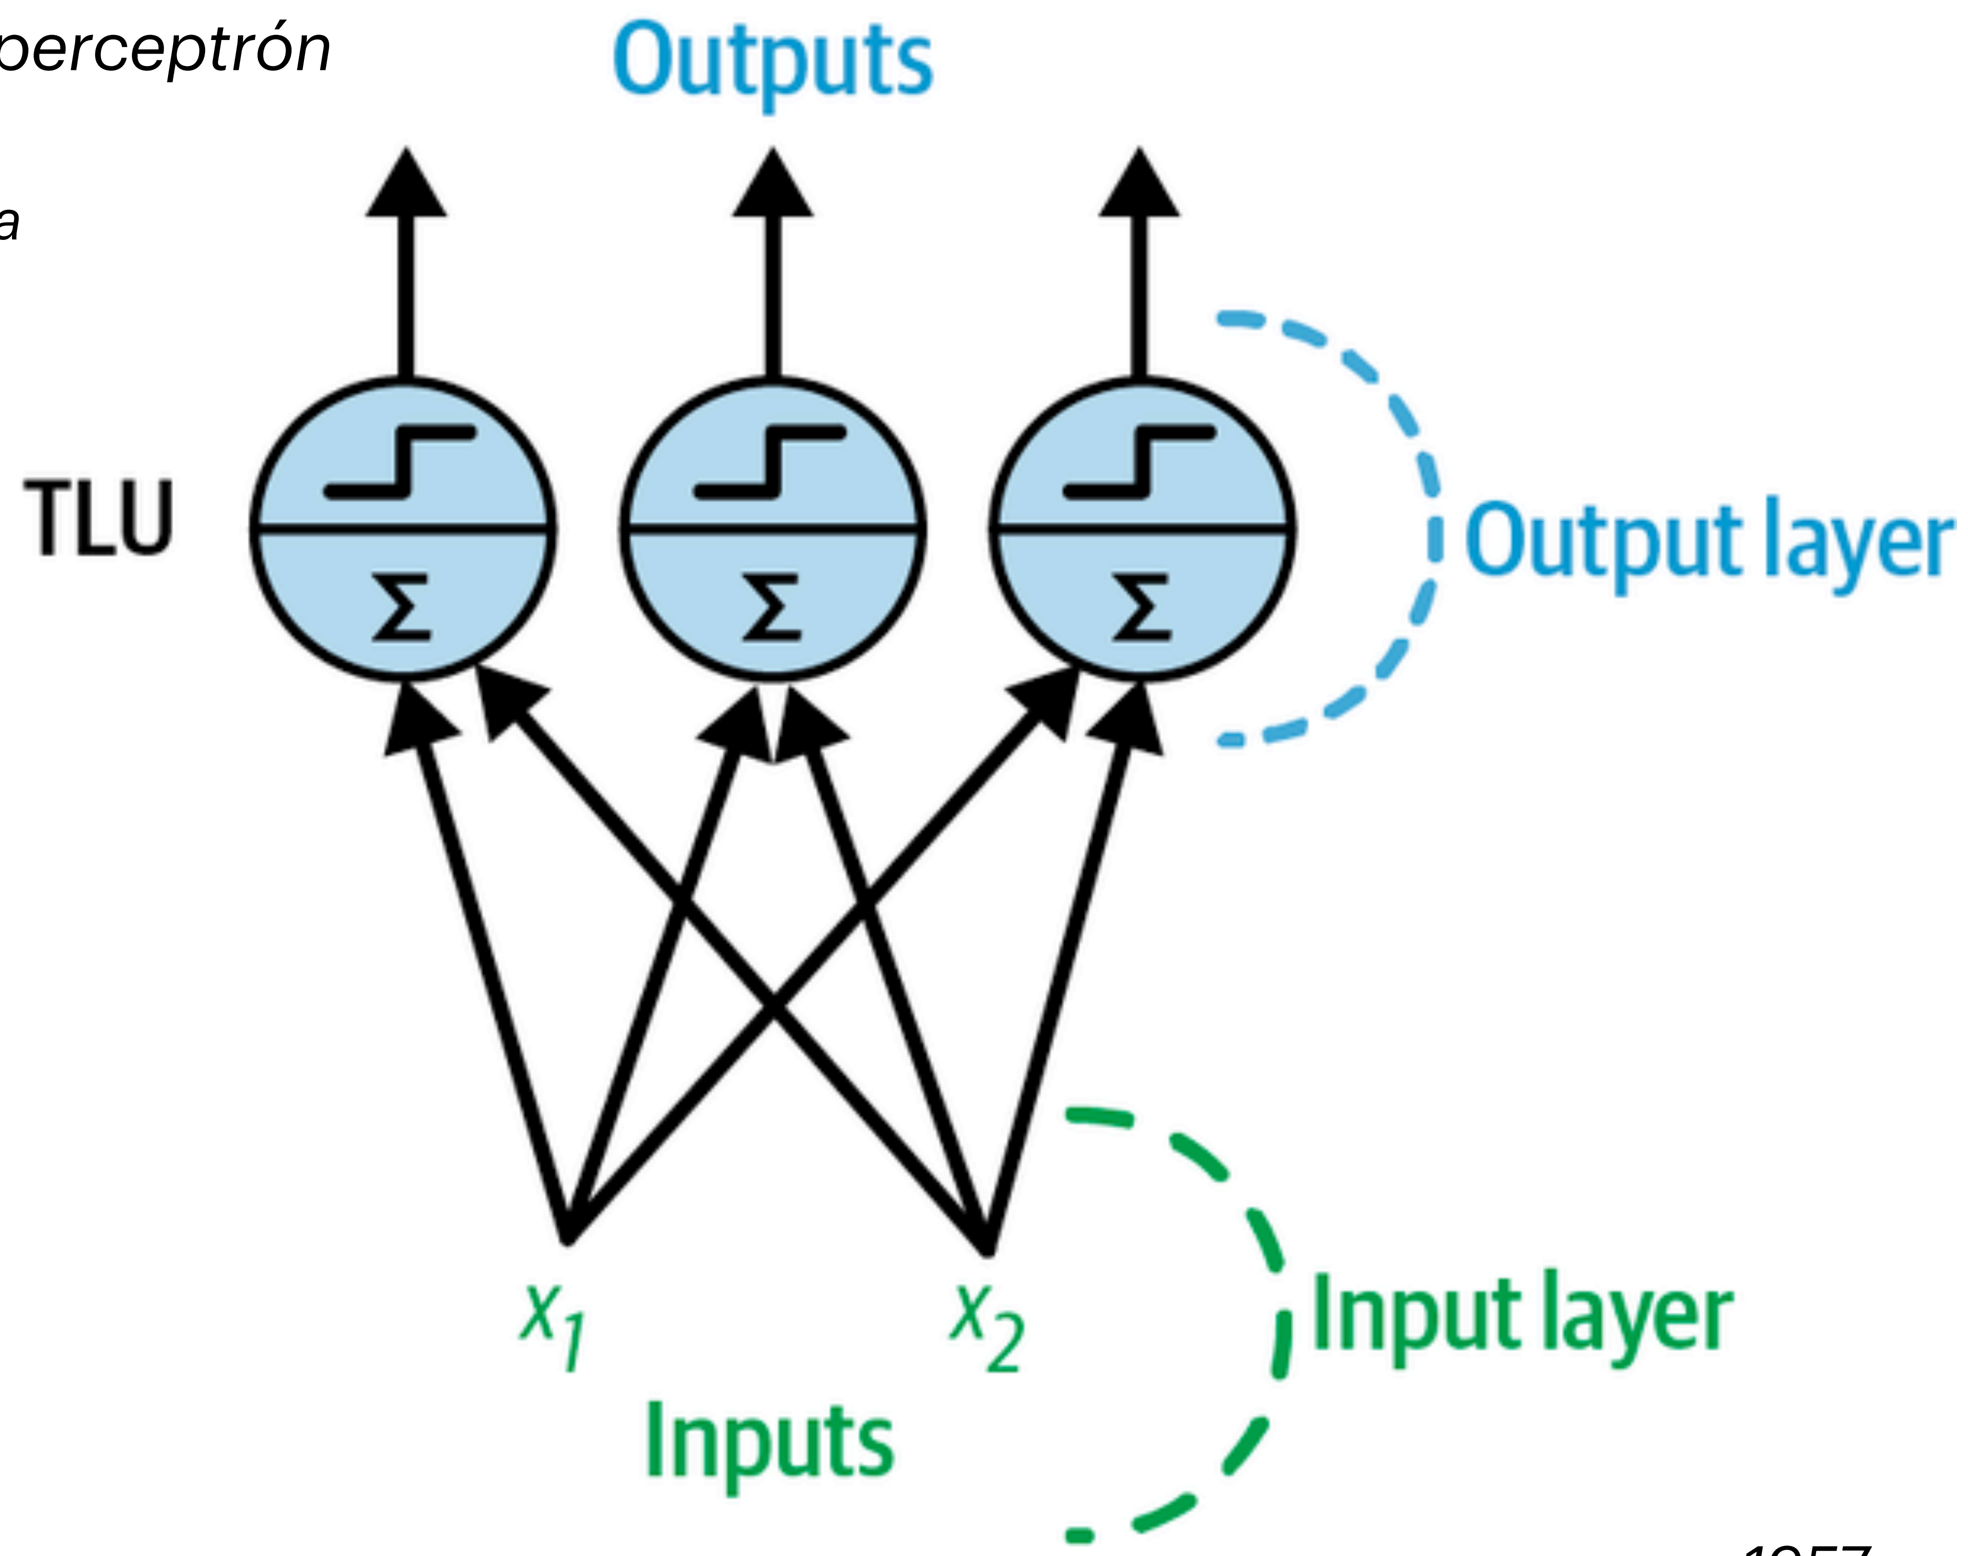

1957 por Frank Rosenblatt

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Las entradas y salidas son números

↓

Luego aplica una función escalonada al resultado

Arquitectura de un perceptrón

$$h_{\mathbf{W},\mathbf{b}}(\mathbf{X}) = \phi(\mathbf{X}\mathbf{W} + \mathbf{b})$$

X *representa la matriz de características de entrada.*

W *contiene todos los pesos de conexión*

b *contiene todos los términos de sesgo*

ϕ *se llama función de activación*

1957 por Frank Rosenblatt

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Las entradas y salidas son números

↓

Luego aplica una función escalonada al resultado

Arquitectura de un perceptrón

$$h_{\mathbf{W},\mathbf{b}}(\mathbf{X}) = \phi(\mathbf{X}\mathbf{W} + \mathbf{b})$$

X *Tiene una fila por instancia y una columna por característica.*

W *Tiene una fila por entrada y una columna por neurona.*

b *uno por neurona*

1957 por Frank Rosenblatt

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Arquitectura de un perceptrón con dos neuronas de entrada y tres de salida

1957 por Frank Rosenblatt

¿Cómo aprendía el preceptron?

$$w_{i,j}^{(\text{next step})} = w_{i,j} + \eta\left(y_j - \hat{y}_j\right)x_i$$

$W_{i,j}$ es el peso de la conexión entre la i -ésima entrada y la j -ésima neurona

X_i es el i- ésimo valor de entrada de la instancia de entrenamiento actual.

$\hat{y}_j$ es la salida de la j- ésima neurona de salida para la instancia de entrenamiento actual.

y_i es la salida objetivo de la j -ésima neurona de salida para la instancia de entrenamiento actual.

η es la tasa de aprendizaje

Intro Deep Learning

Perceptron

unidad lógica de umbral (TLU)

Arquitectura de un perceptrón con dos neuronas de entrada y tres de salida

1957 por Frank Rosenblatt

$$w_{i,j}^{(\text{next step})} = w_{i,j} + \eta\left(y_j - \hat{y}_j\right)x_i$$

Limitaciones de un perceptrón.

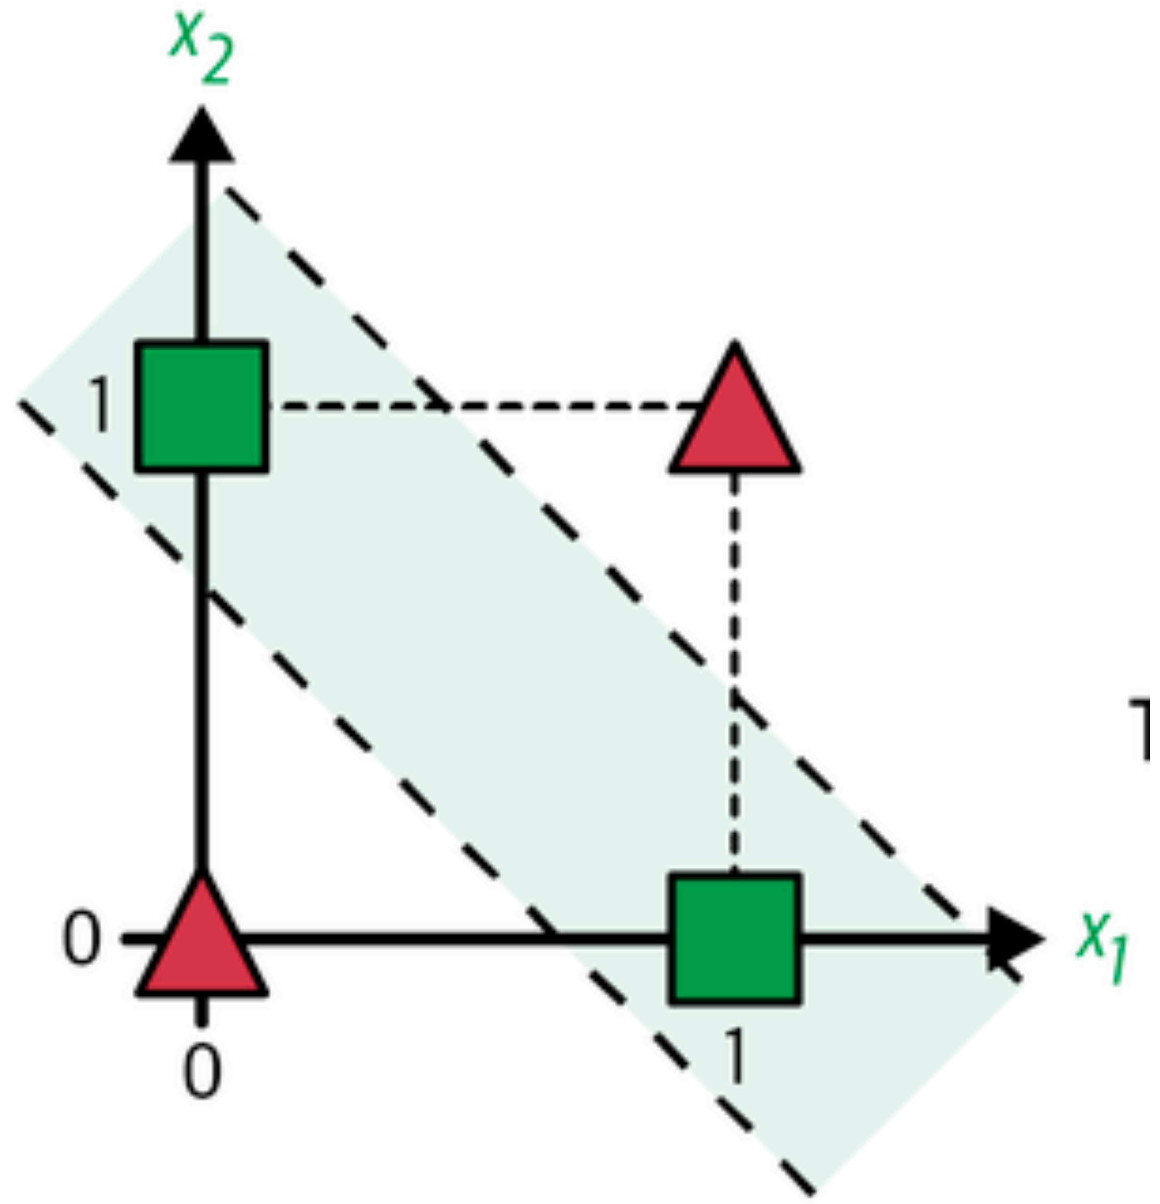

1

Pontificia Universidad JAVERIANA Colombia

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Invierno de la I.A.

1957, Frank Rosenblatt

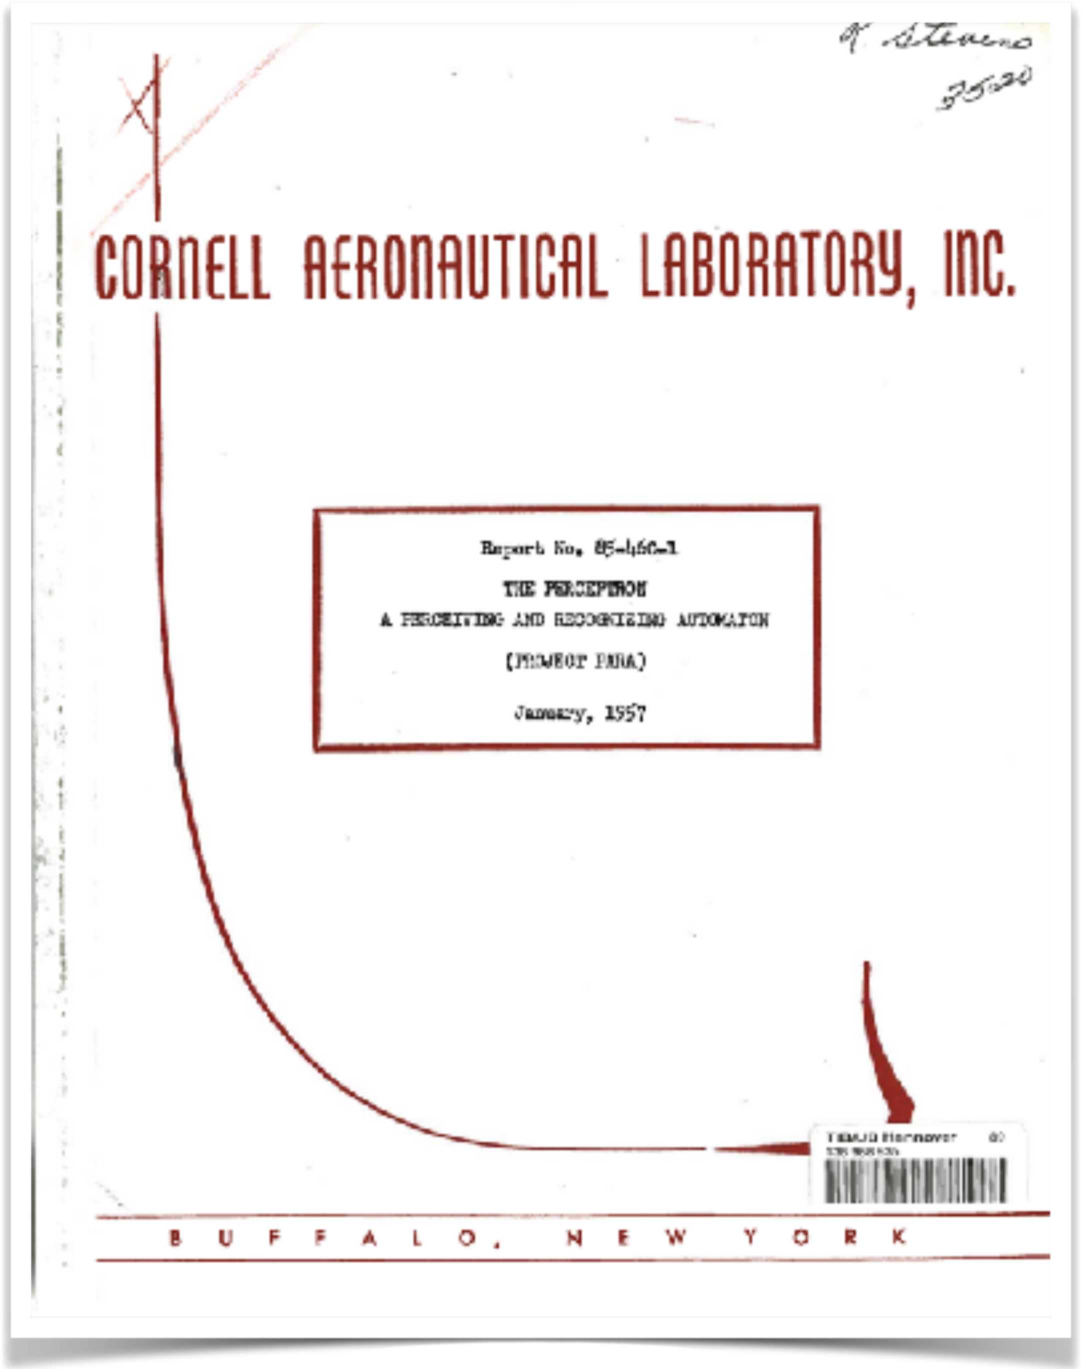
CORNELL AERONAUTICAL LABORATORY, INC.

Report No. 85-460-1

THE PERCEPTRON

A PERCEIVING AND RECOGNIZING AUTOMATON

(PROJECT PARA)

January, 1957

B U F F A L O , N E W Y O R K

The Perceptron:

A Perceiving and recognizing automation.

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

↓

Invierno de la I.A.

1985, David Rumelhart, Geoffrey Hinton y Ronald Williams

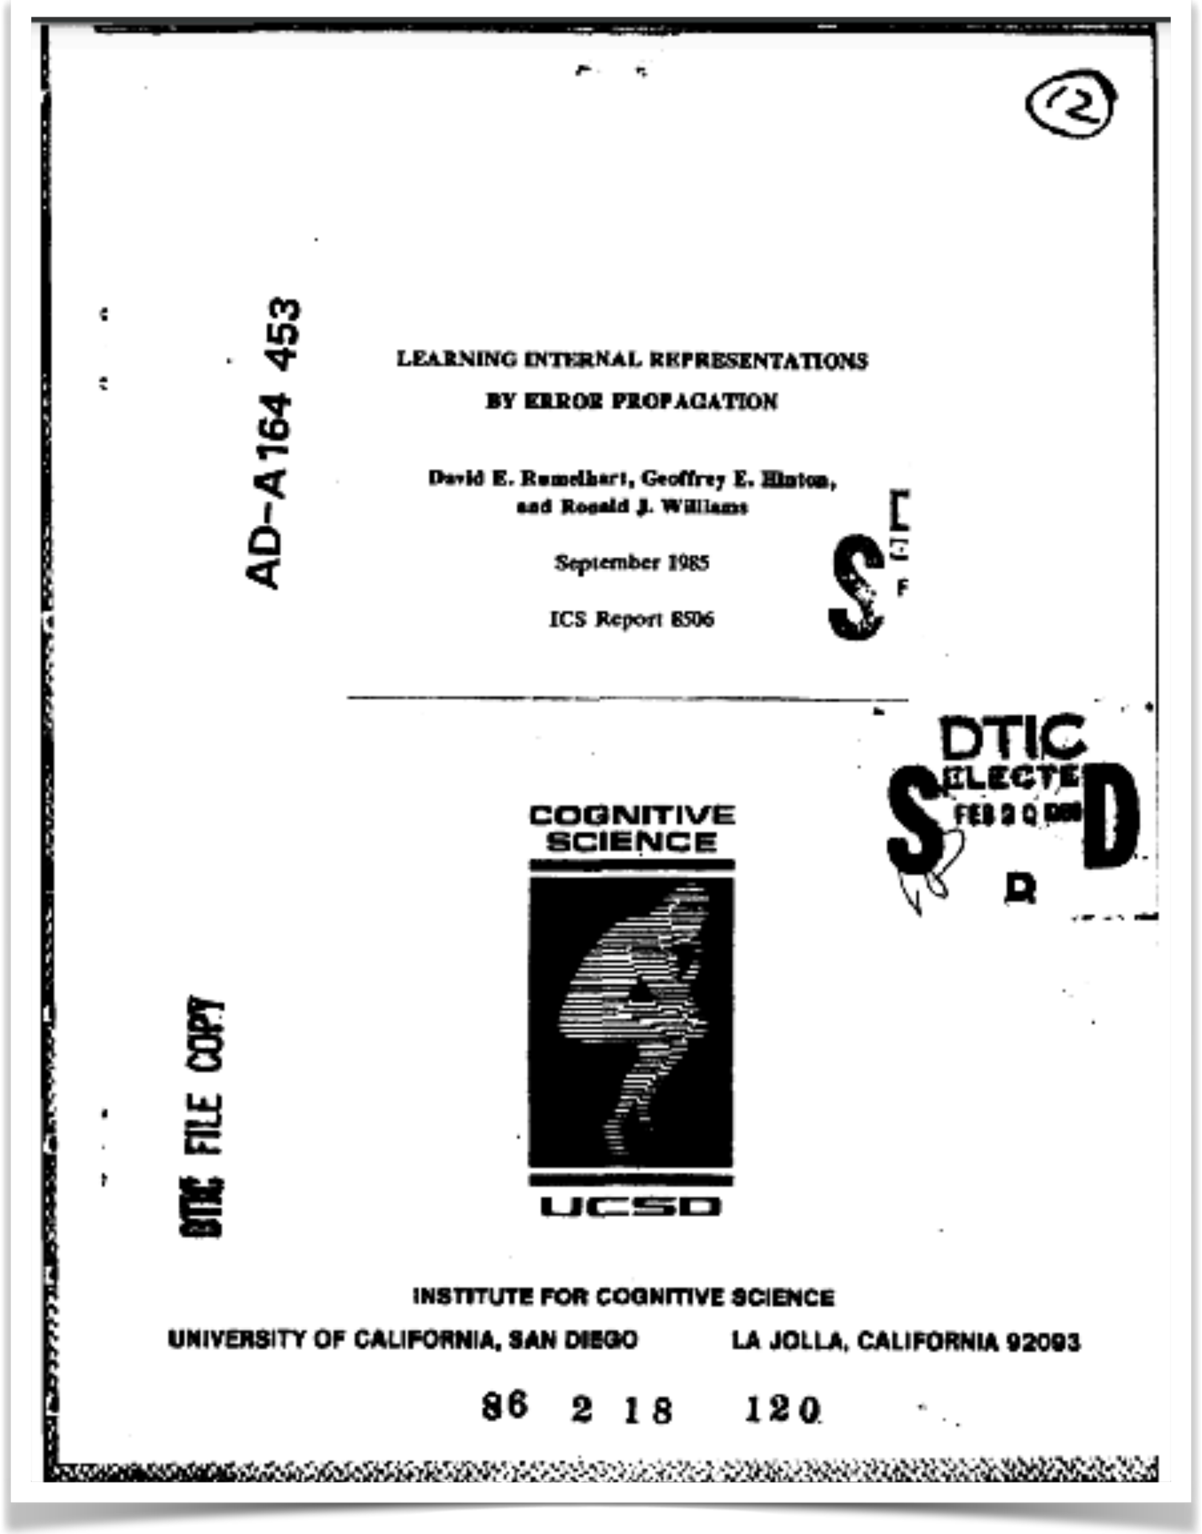

AD-A164 453

LEARNING INTERNAL REPRESENTATIONS
BY ERROR PROPAGATION

David E. Rumelhart, Geoffrey E. Hinton,
and Ronald J. Williams

September 1985

ICS Report 8506

DTIC ELECTE

COGNITIVE SCIENCE

UCSD

DTIC FILE COPY

INSTITUTE FOR COGNITIVE SCIENCE
UNIVERSITY OF CALIFORNIA, SAN DIEGO LA JOLLA, CALIFORNIA 92093

86 2 18 120

Learning Internal Representation by error propagation

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

↓

Invierno de la I.A.

1986, David Rumelhart, Geoffrey Hinton y Ronald Williams

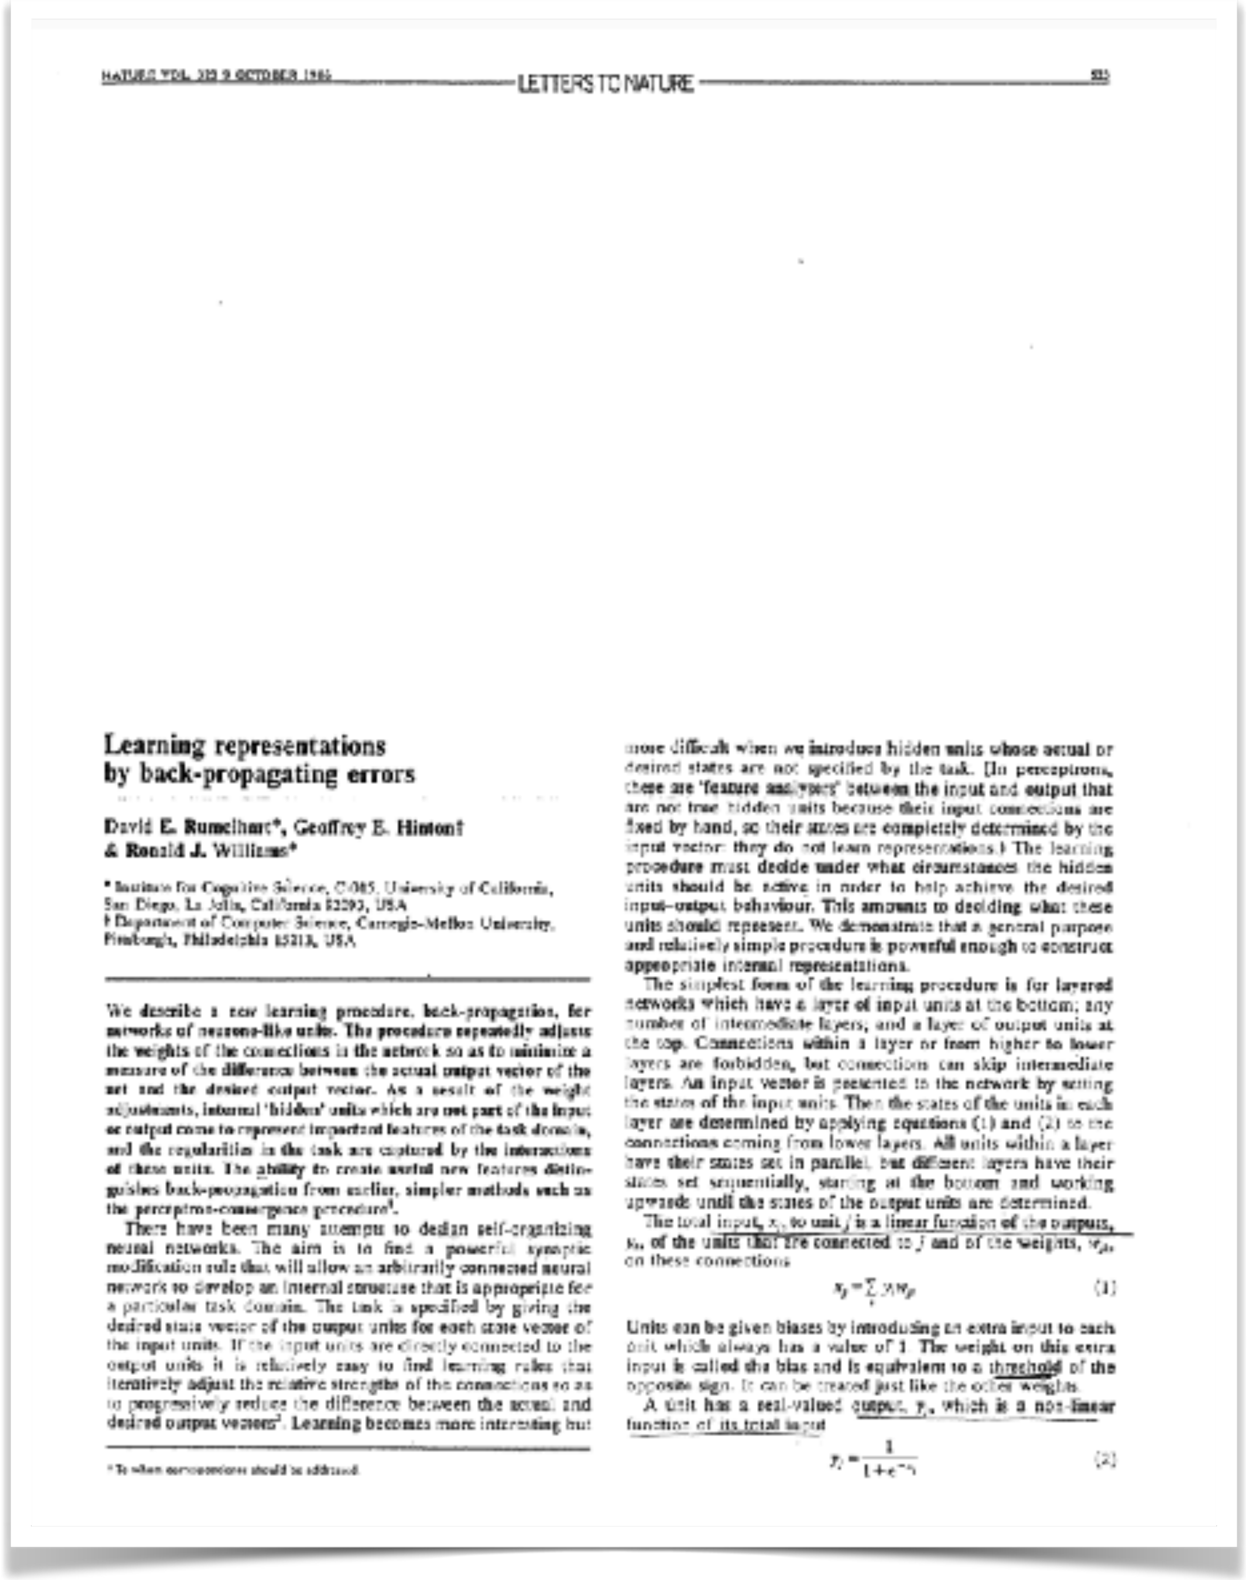
NATURE VOL. 323 9 OCTOBER 1986 — LETTERS TO NATURE — 533

Learning representations by back-propagating errors

David E. Rumelhart*, Geoffrey E. Hinton† & Ronald J. Williams*

* Institute for Cognitive Science, C-015, University of California, San Diego, La Jolla, California 92093, USA
† Department of Computer Science, Carnegie-Mellon University, Pittsburgh, Philadelphia 15213, USA

Learning Representations by back-propagation errors

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

↓

Invierno de la I.A.

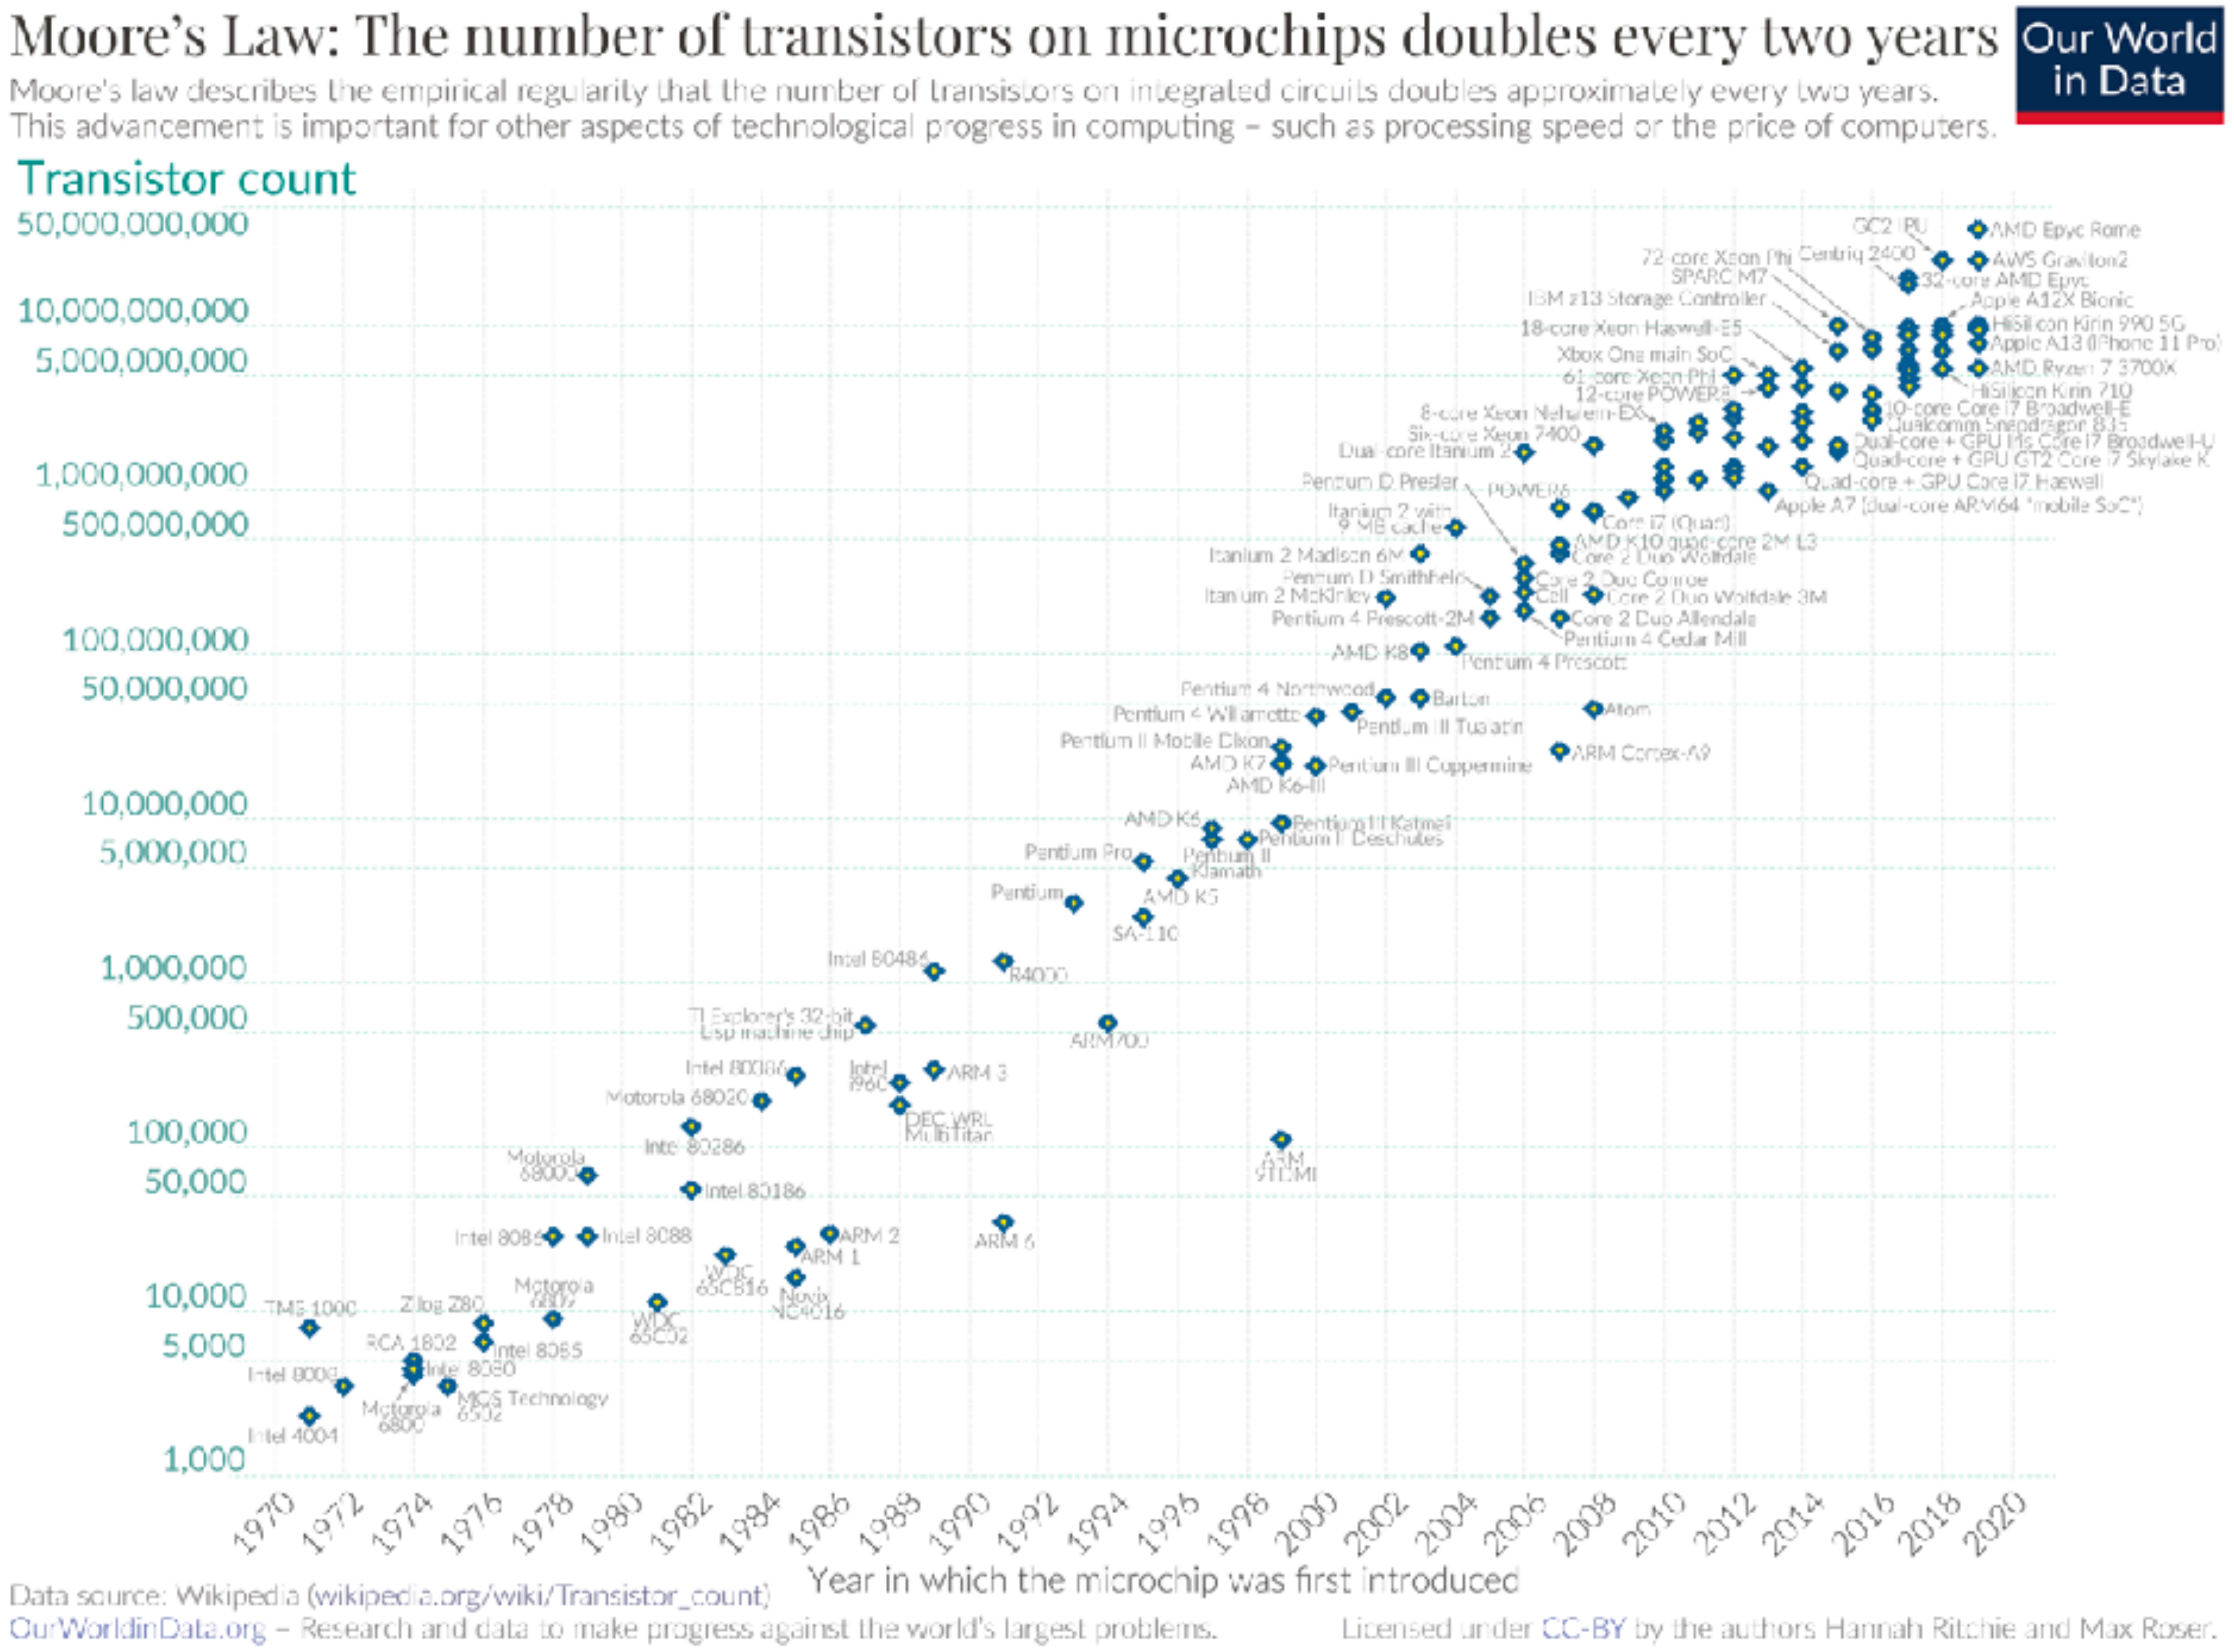

Intro Deep Learning

Multi-Layer Perceptron

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Problema de clasificación XOR y un MLP que lo resuelve

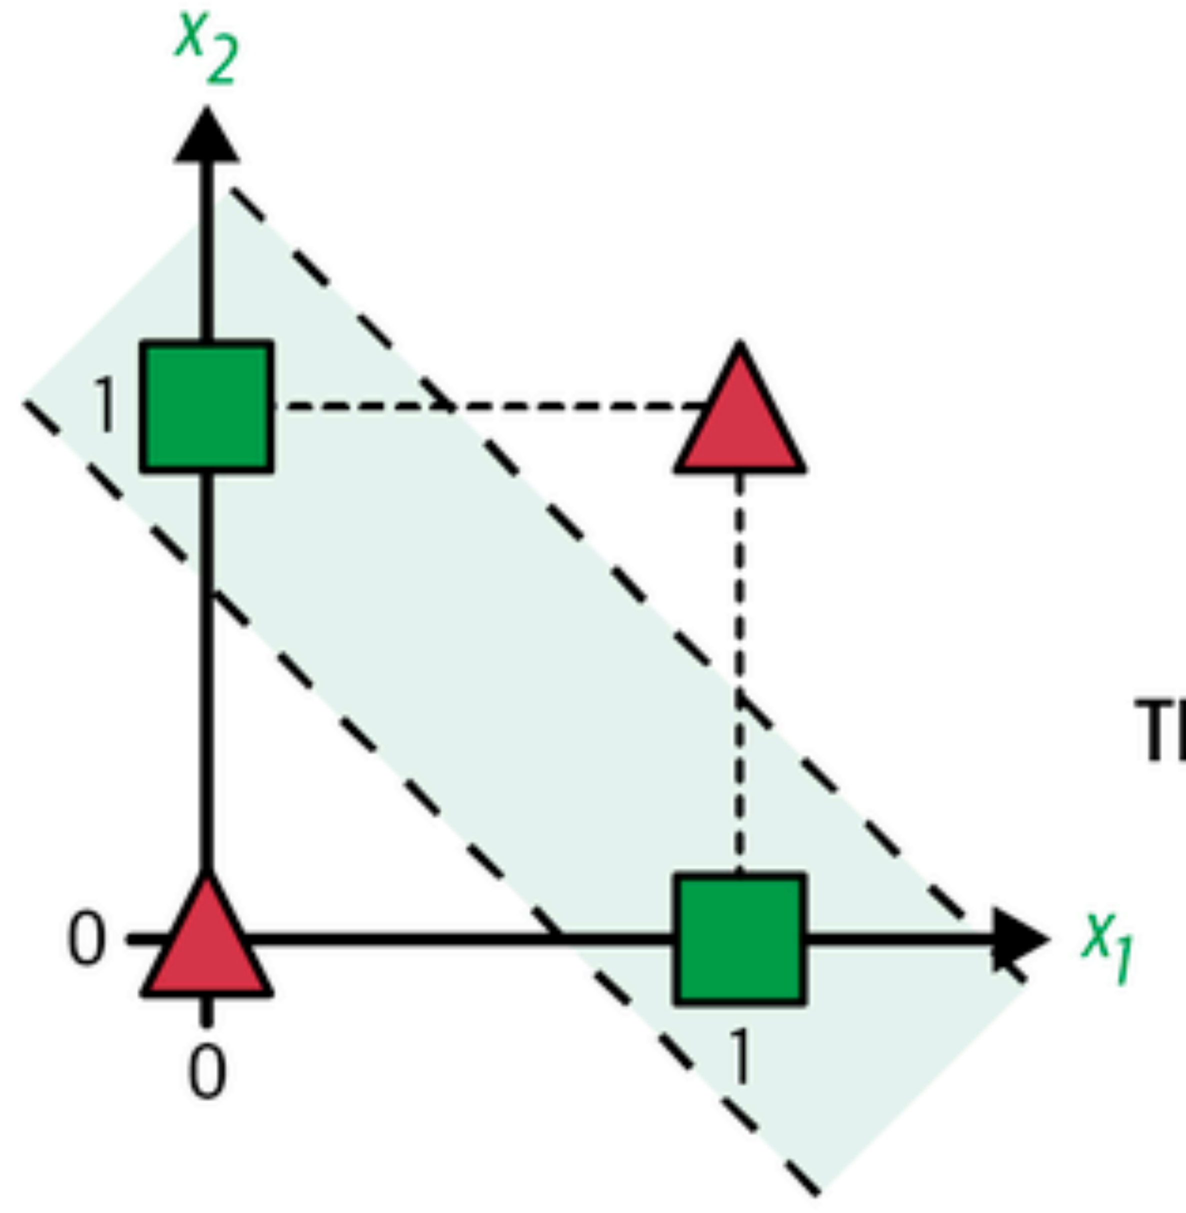

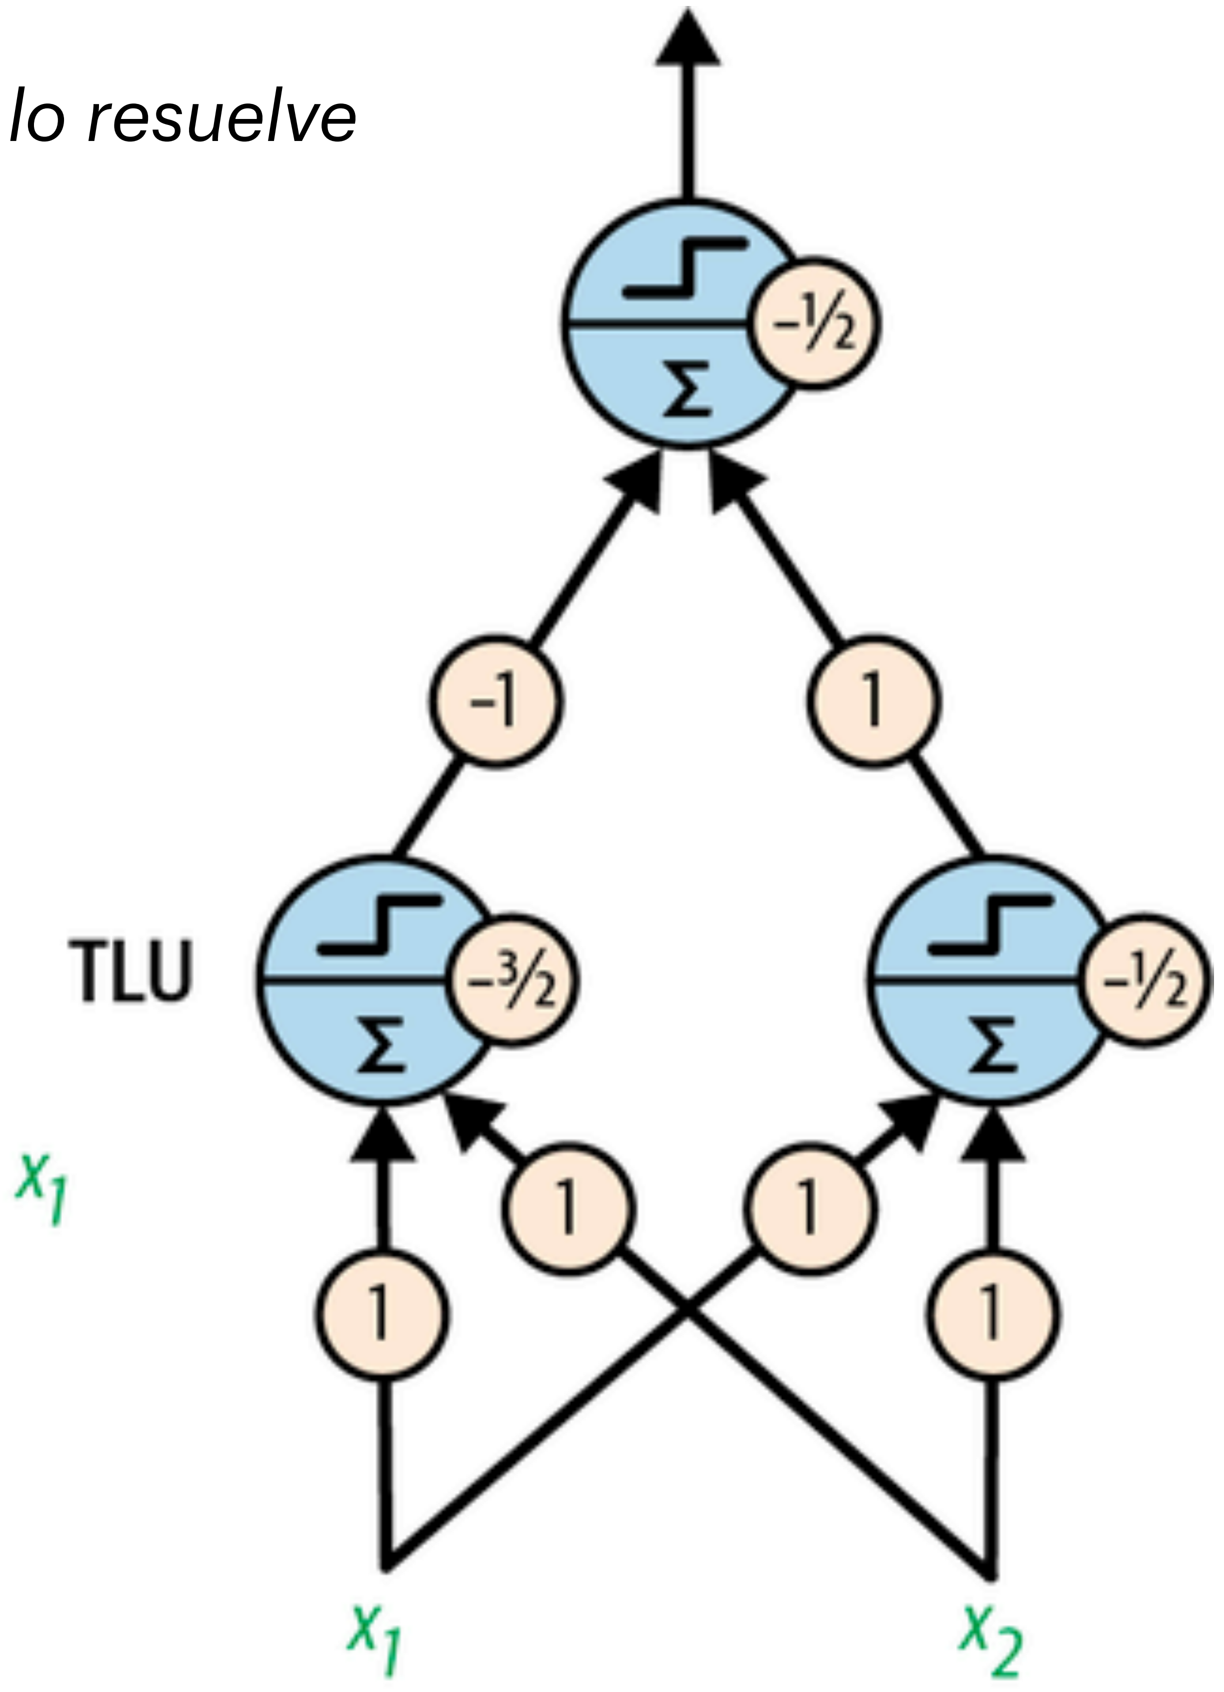

Perceptrons de 1969 , Marvin Minsky y Seymour Papert

Intro Deep Learning

Multi-Layer Perceptron

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

<u>MLP se compone de:</u>

- *Una capa de entrada*
- *Una o más capas ocultas*
- *Una capa de salida*

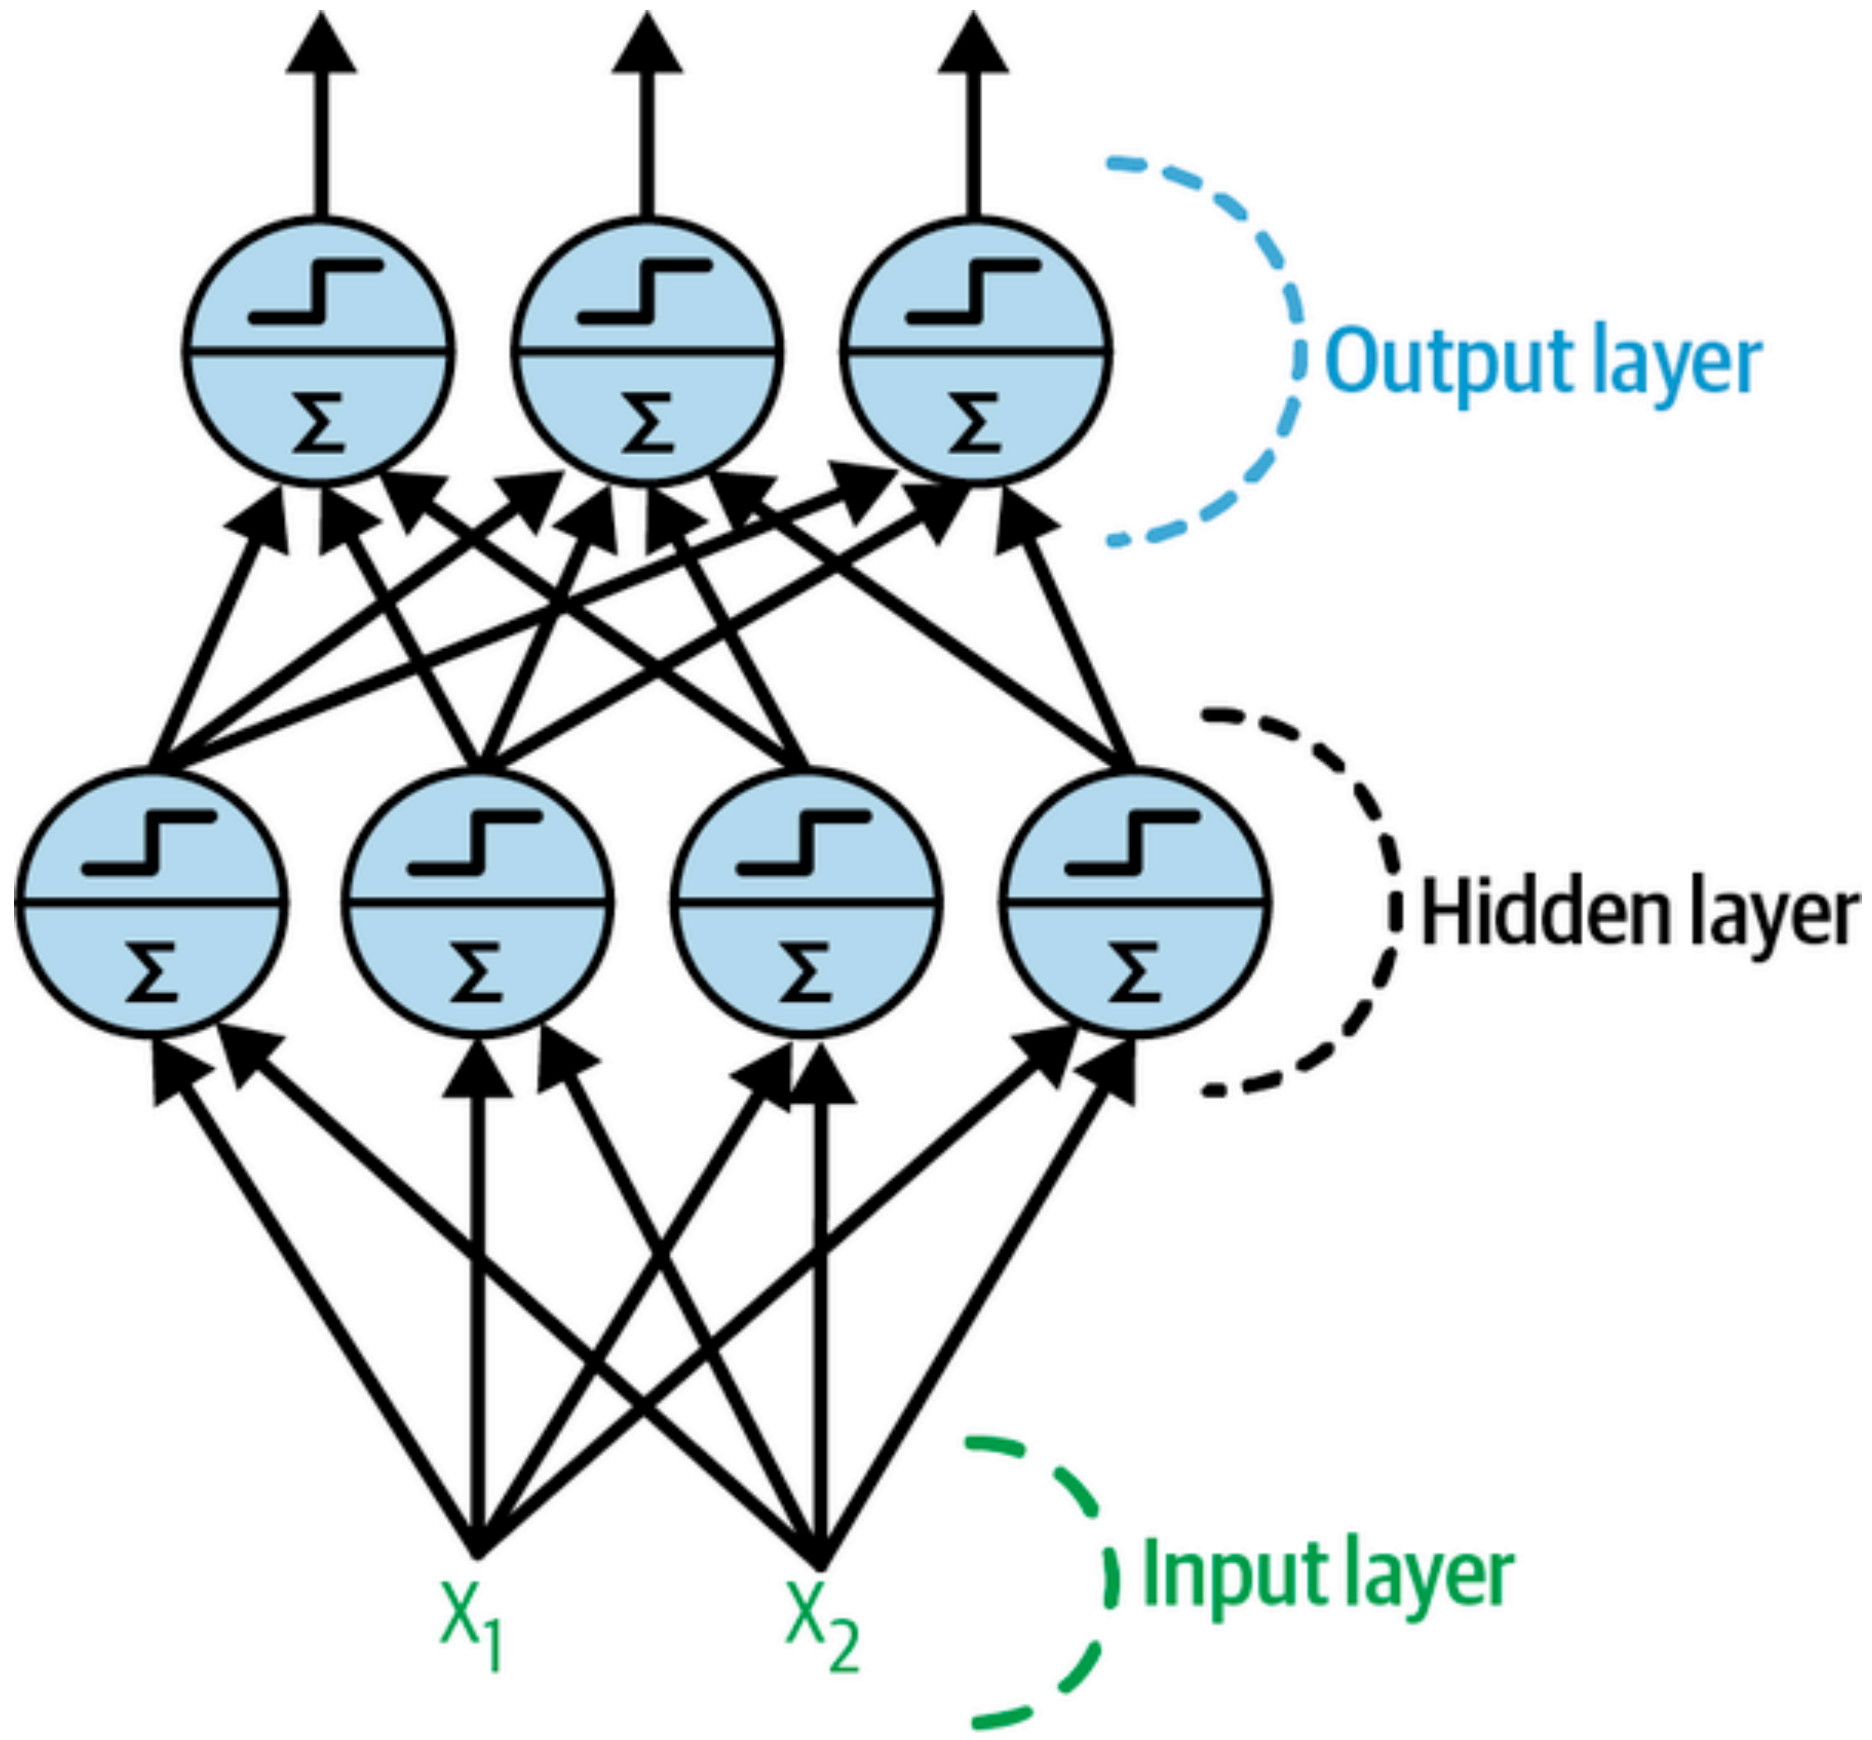

Perceptrons de 1969 , Marvin Minsky y Seymour Papert

Intro Deep Learning

Multi-Layer Perceptron

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

MLP classificación:

Un MLP moderno (incluidos ReLU y softmax) para clasificación

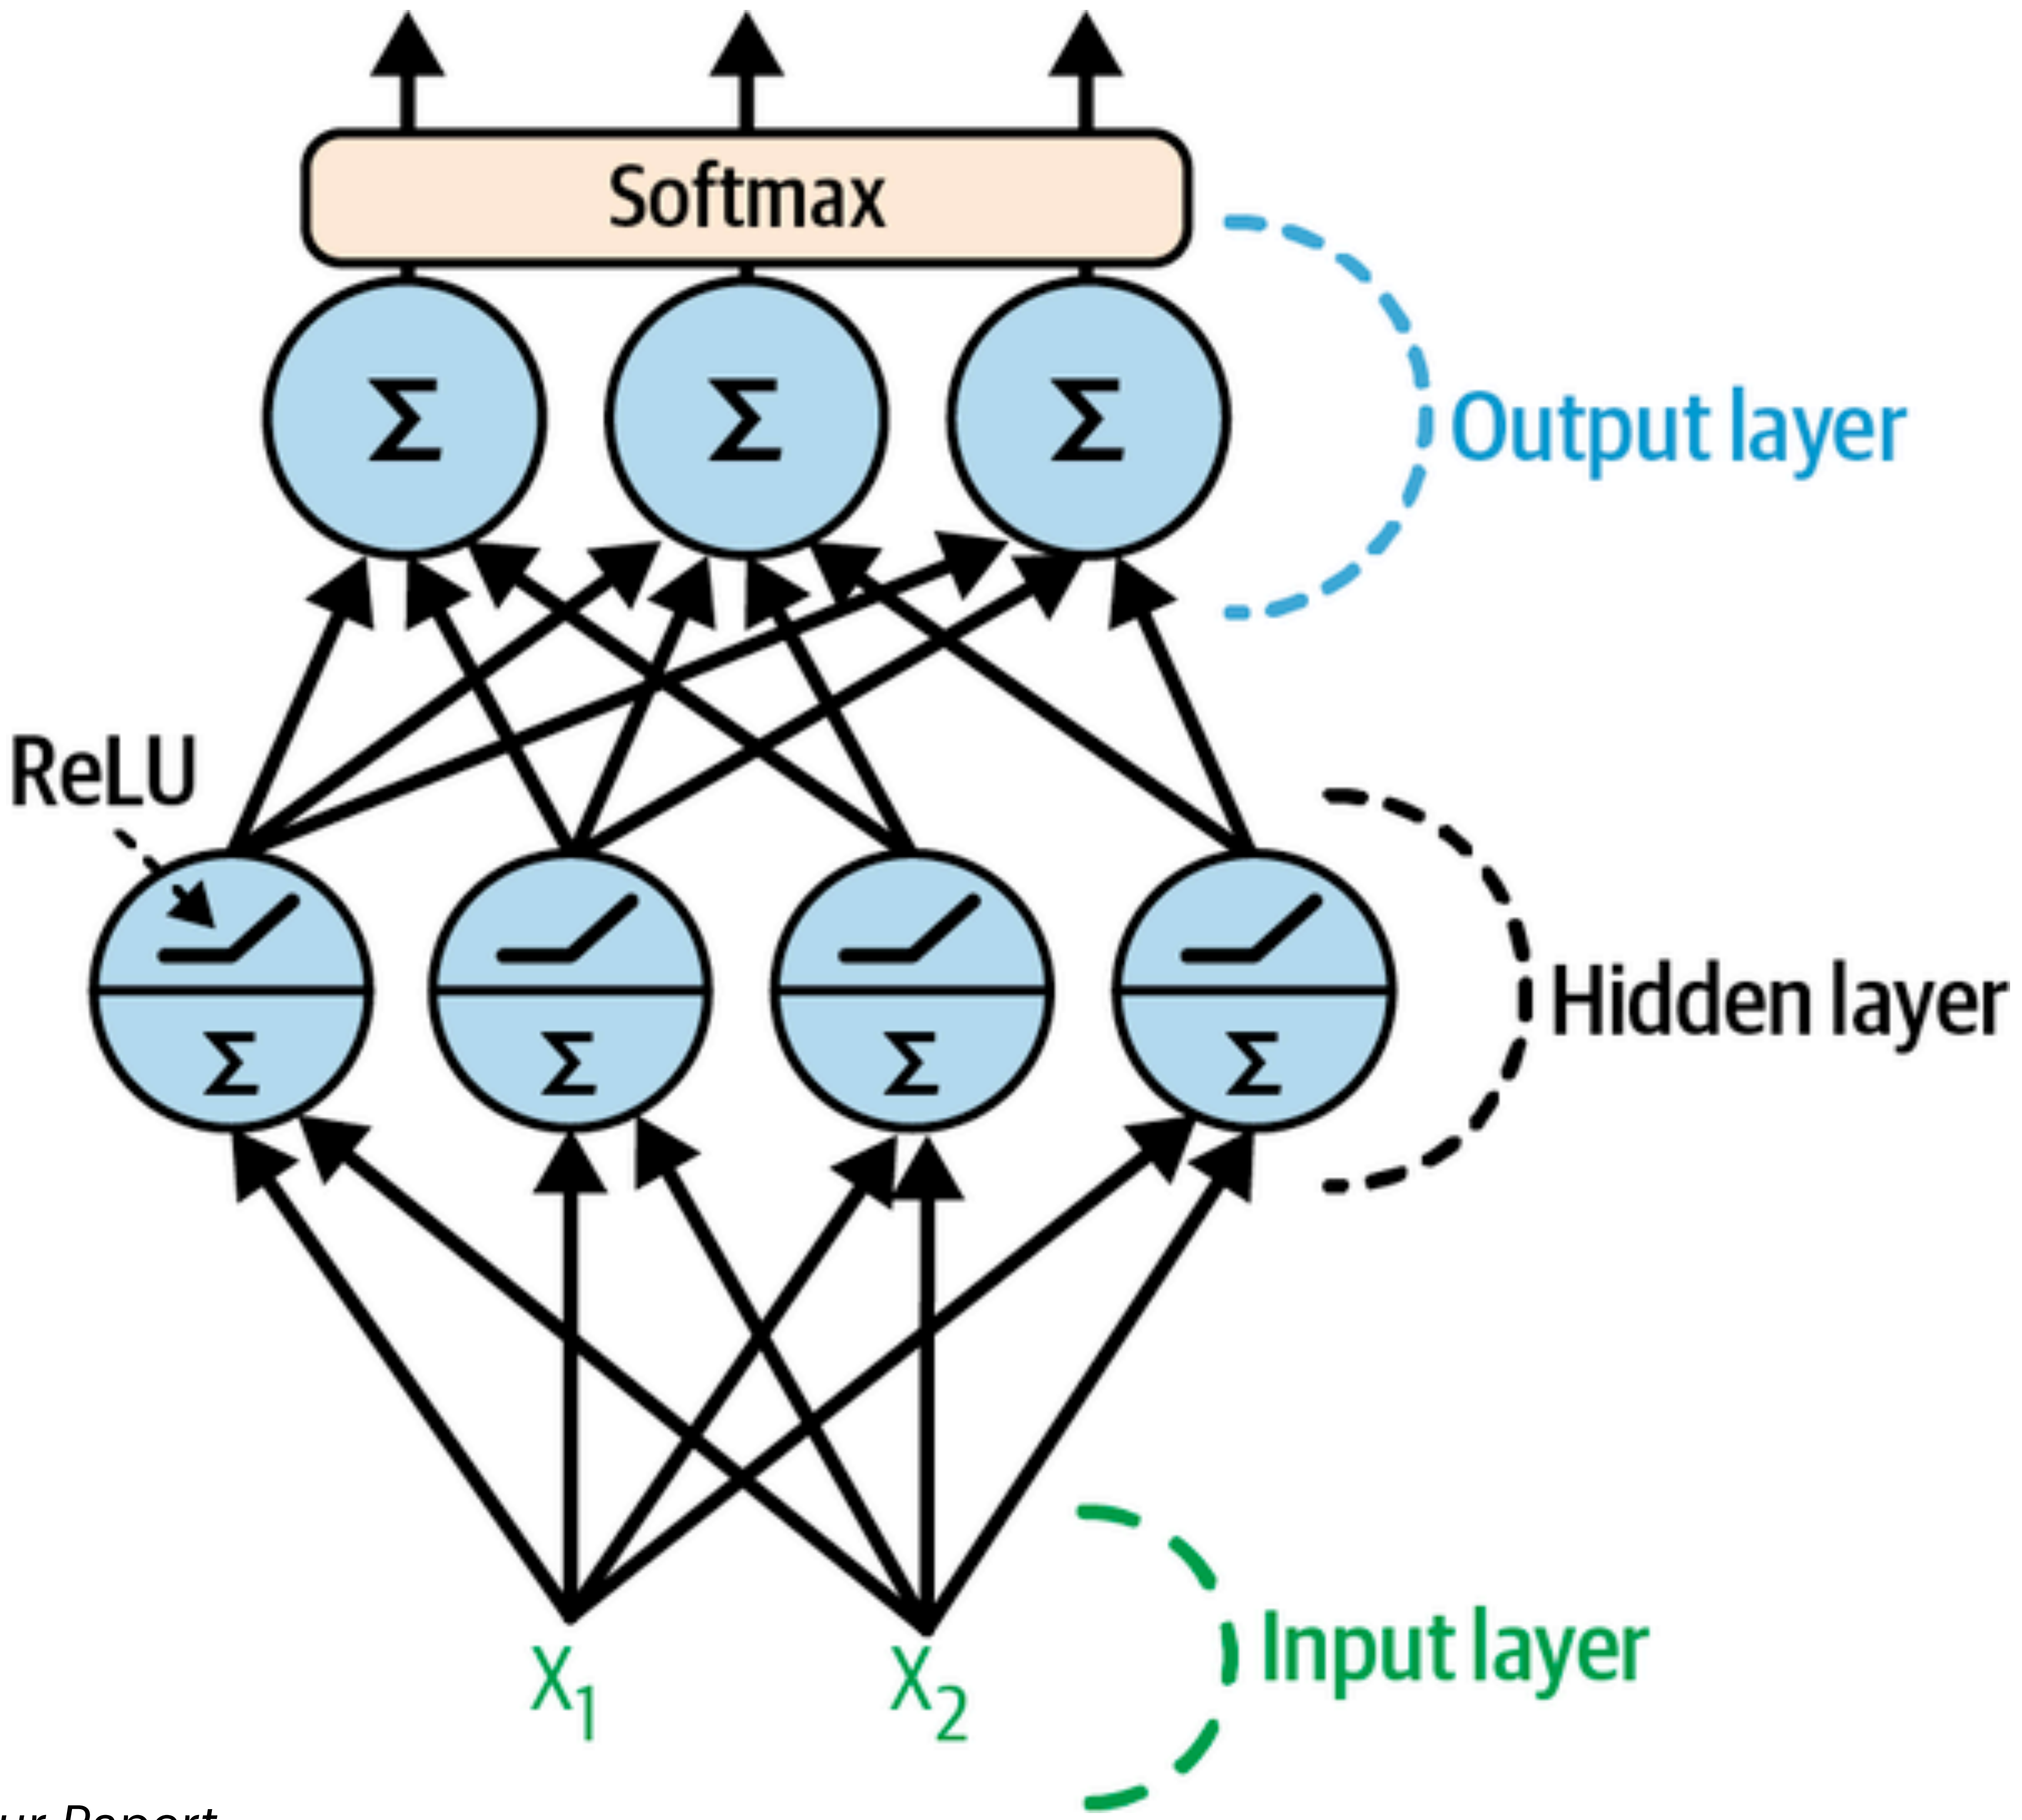

Perceptrons de 1969 , Marvin Minsky y Seymour Papert

Intro Deep Learning

Multi-Layer Perceptron

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

¿Por qué usamos funciones de activación?

¿Qué pasa si sumamos varias neuronas sin una función de activación?

¿Por qué nuestra salida debe ser una salida no lineal?

Perceptrons de 1969 , Marvin Minsky y Seymour Papert

Intro Deep Learning

Multi-Layer Perceptron

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

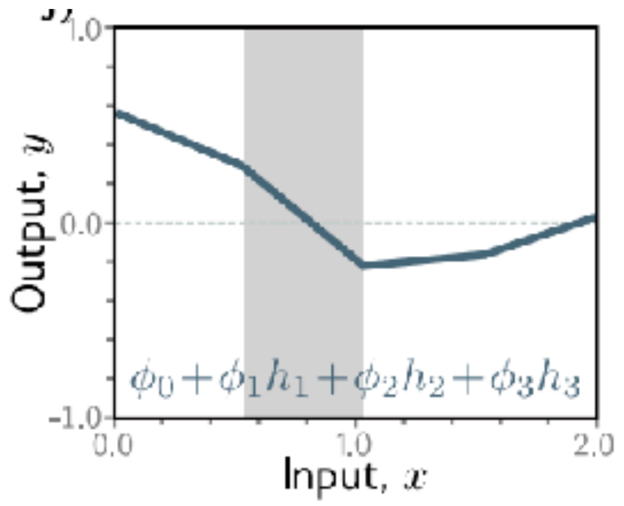

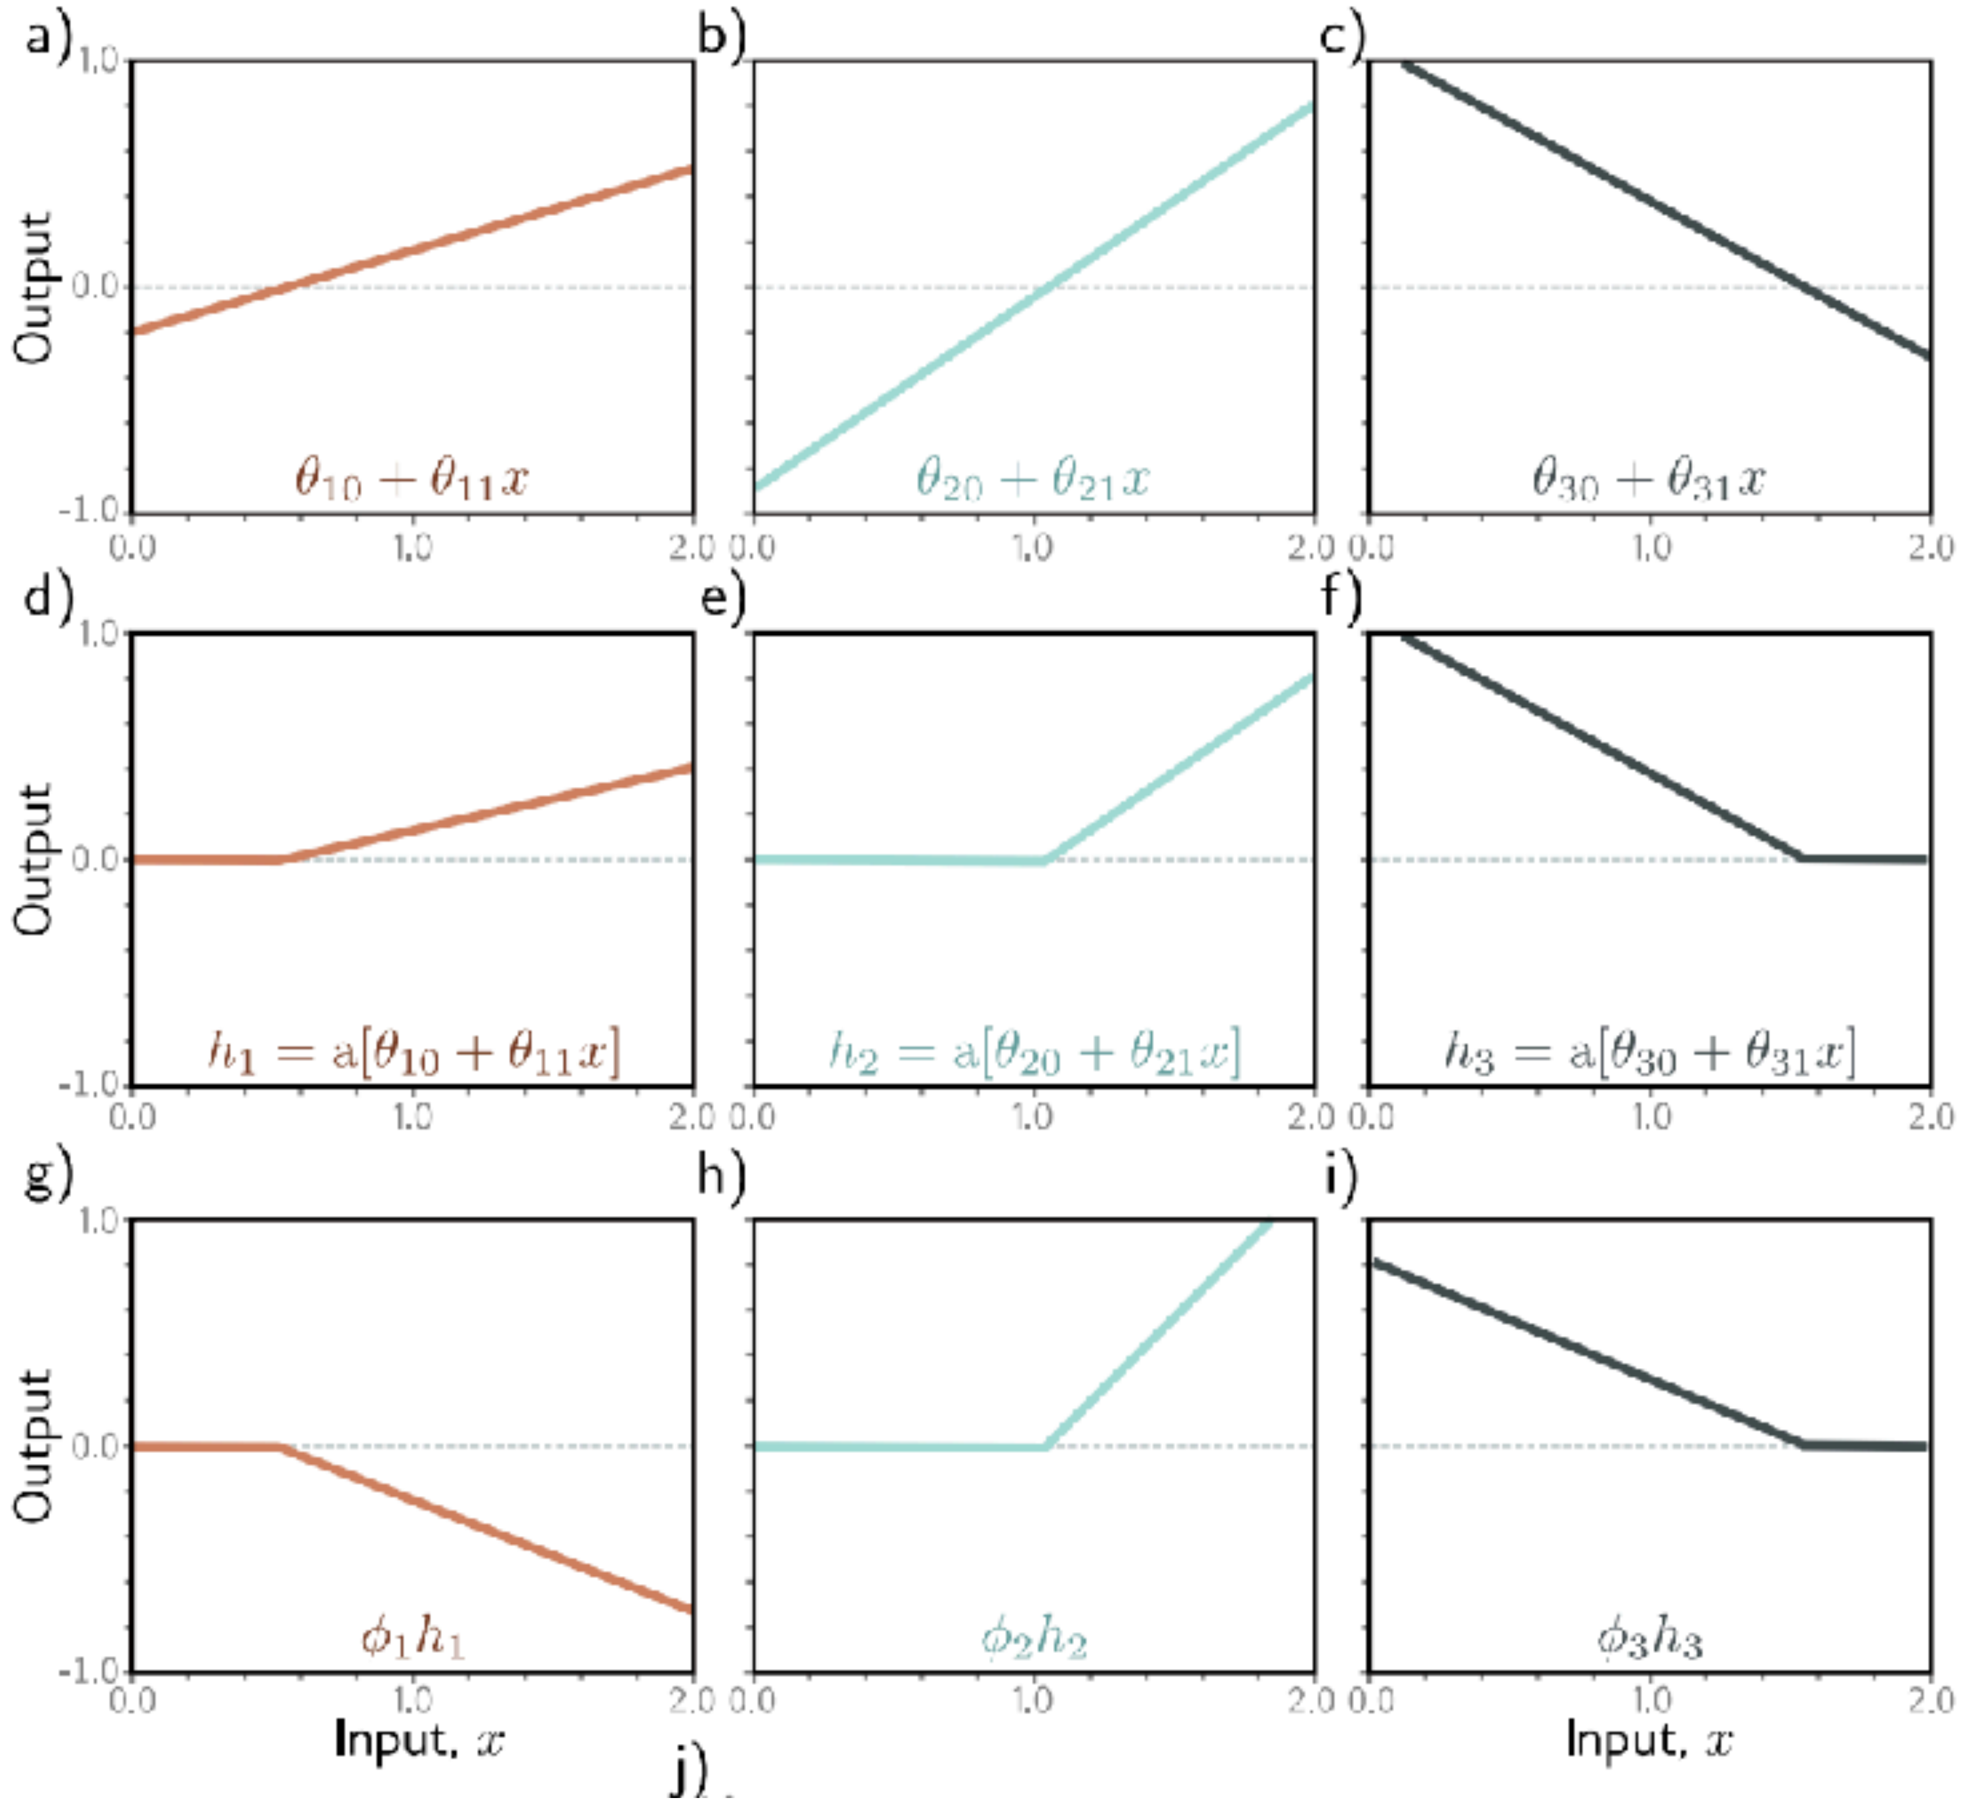

Prince 3023, Understanding Deep Learning

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

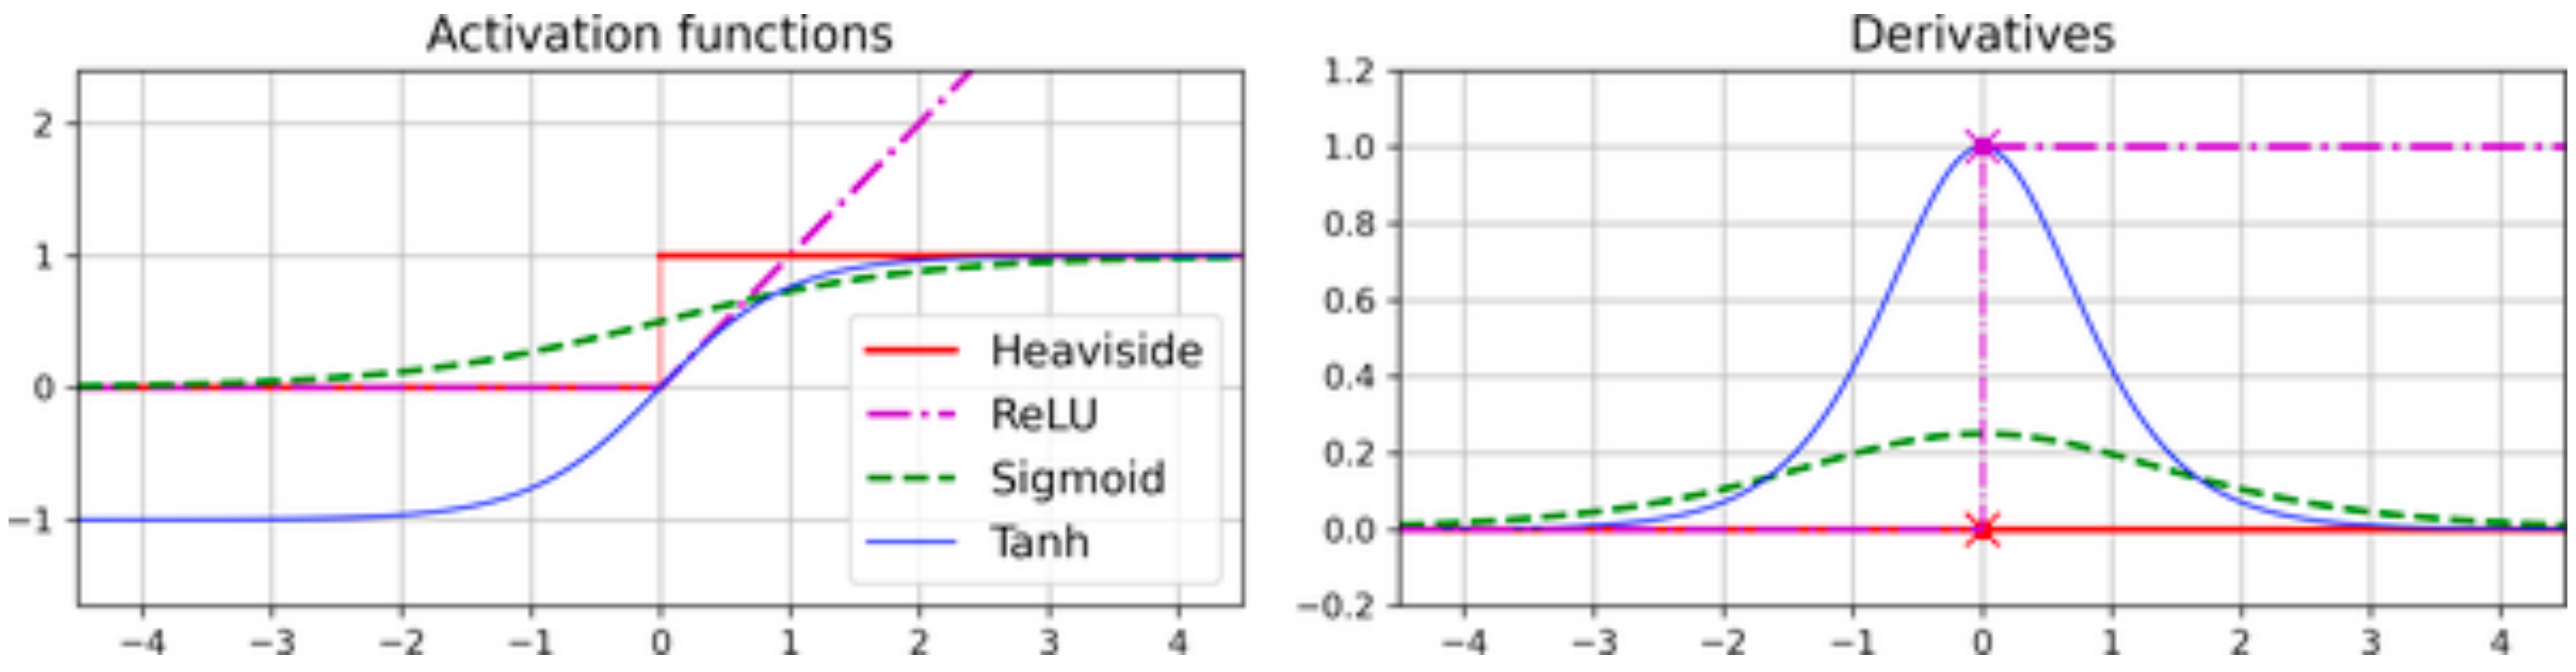

1985, David Rumelhart, Geoffrey Hinton y Ronald Williams

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

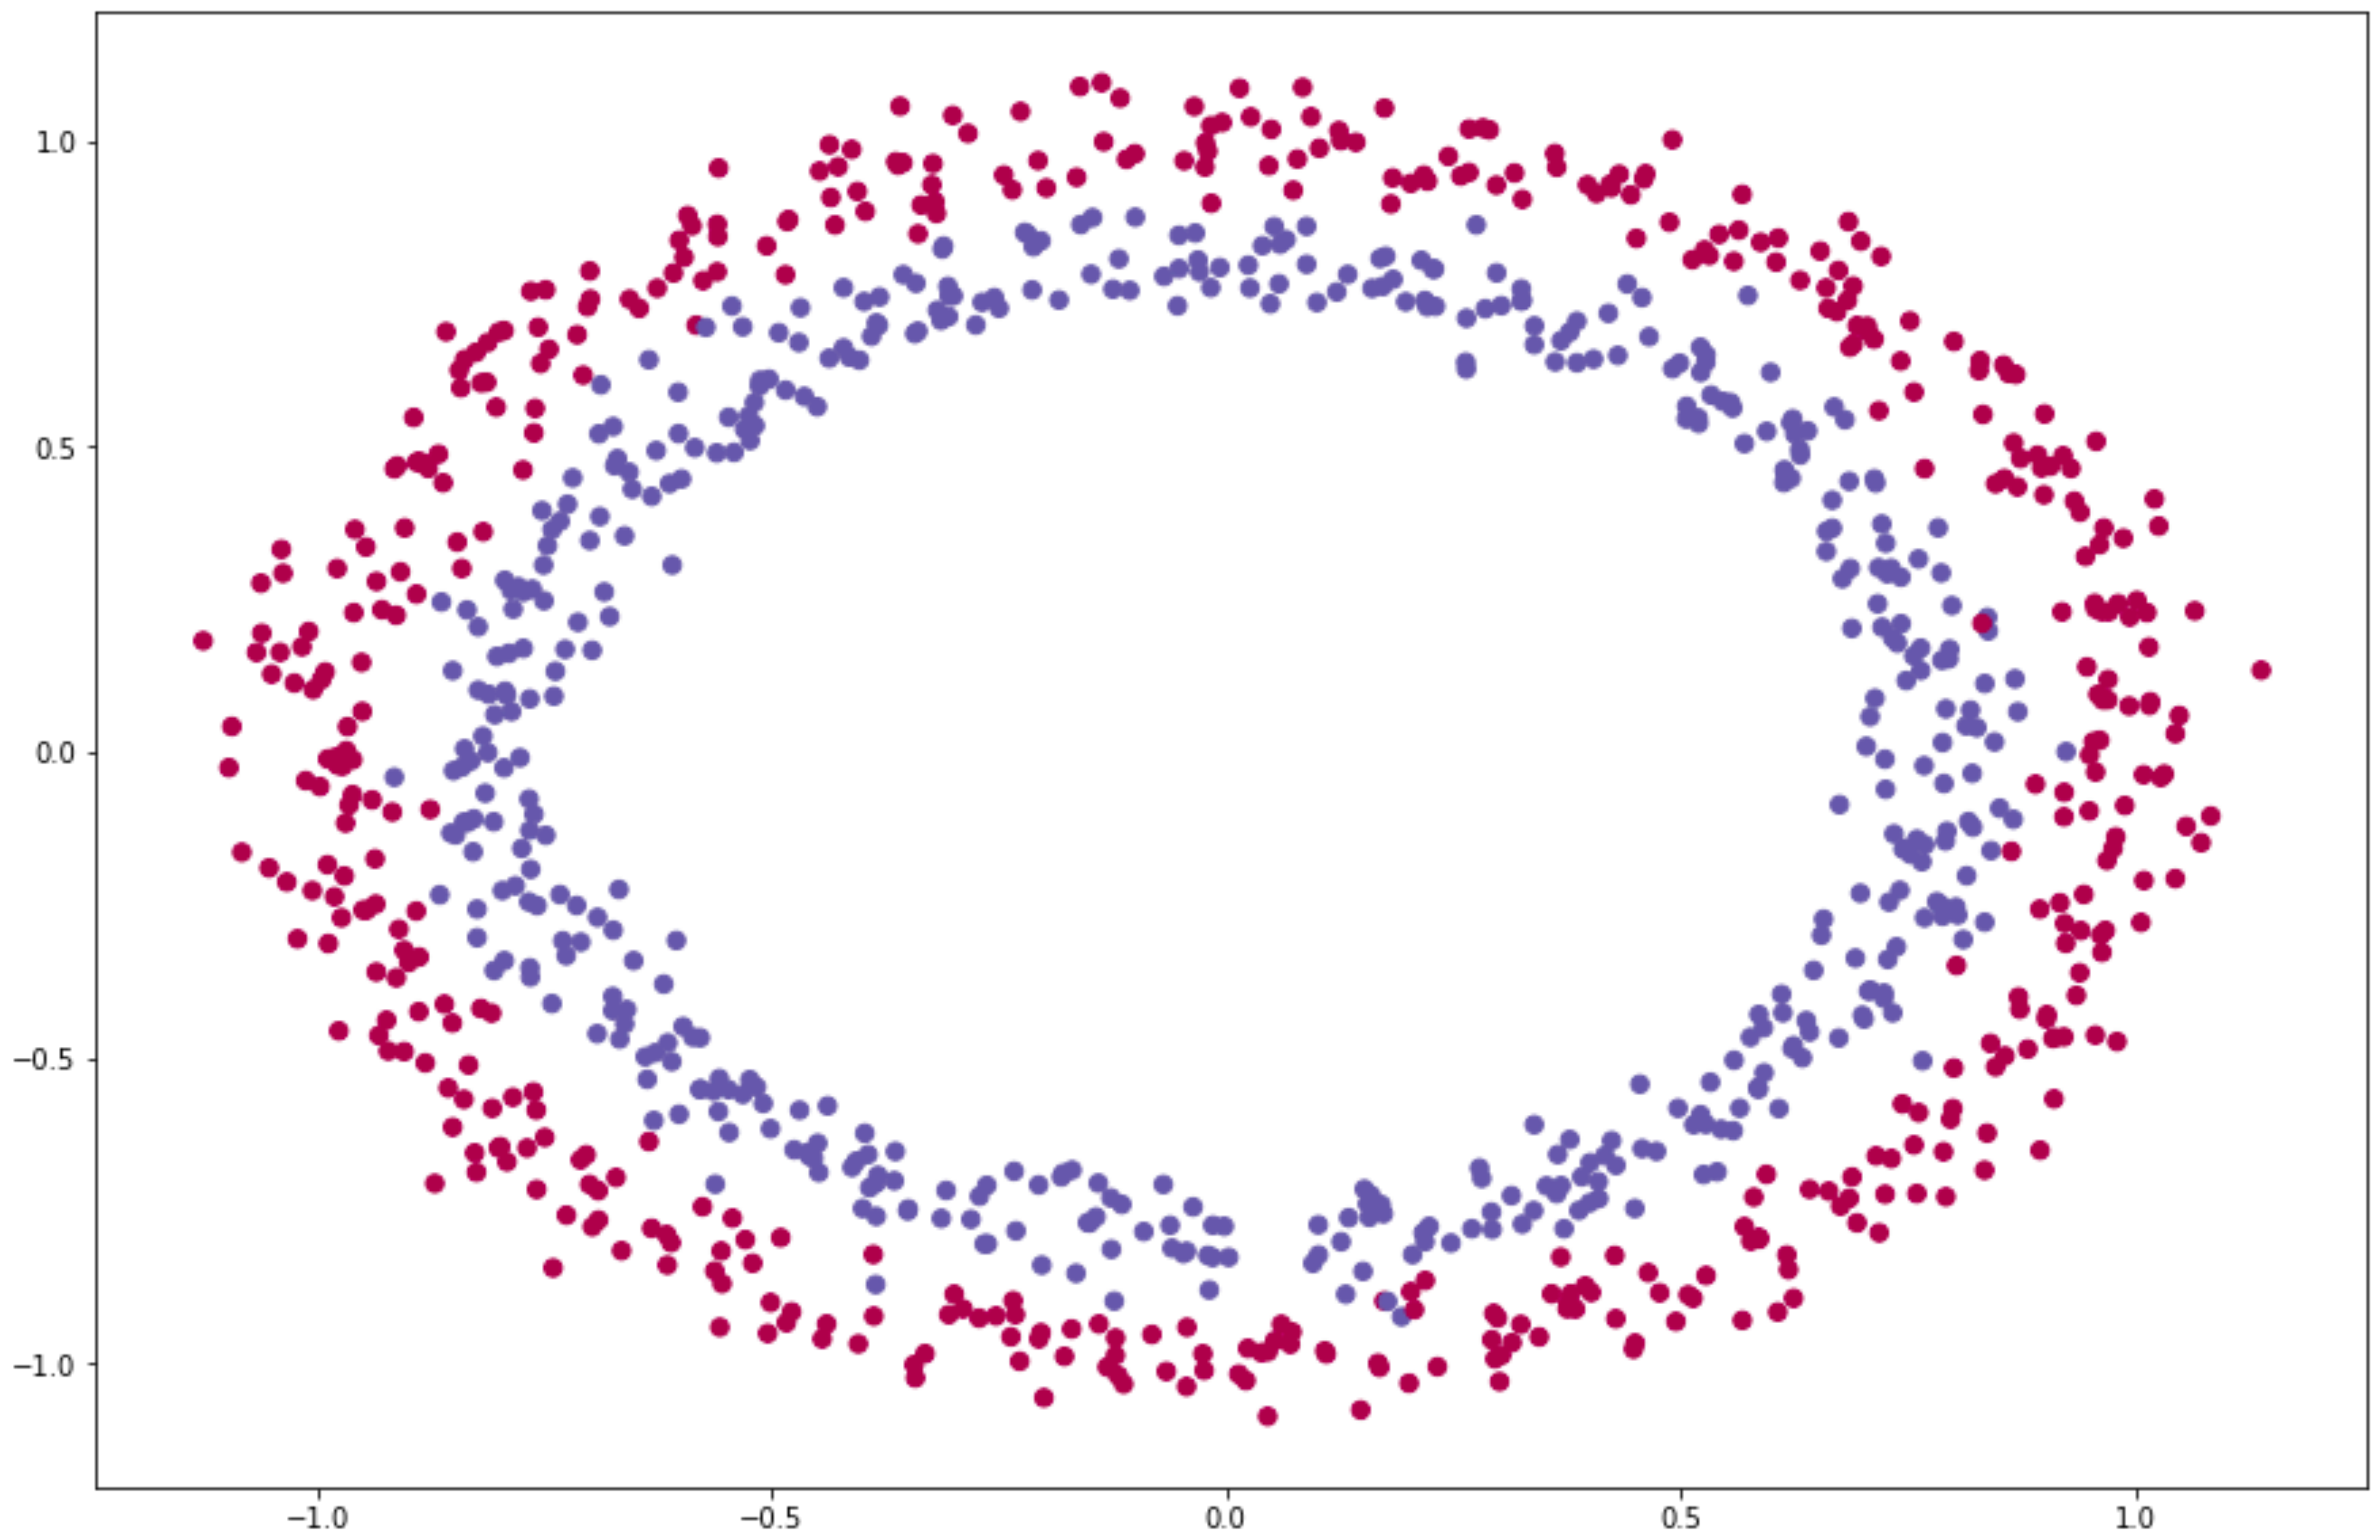

Intro Deep Learning

Multi-Layer Perceptron - Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Función geométrica de una red neuronal con 4 neuronas.

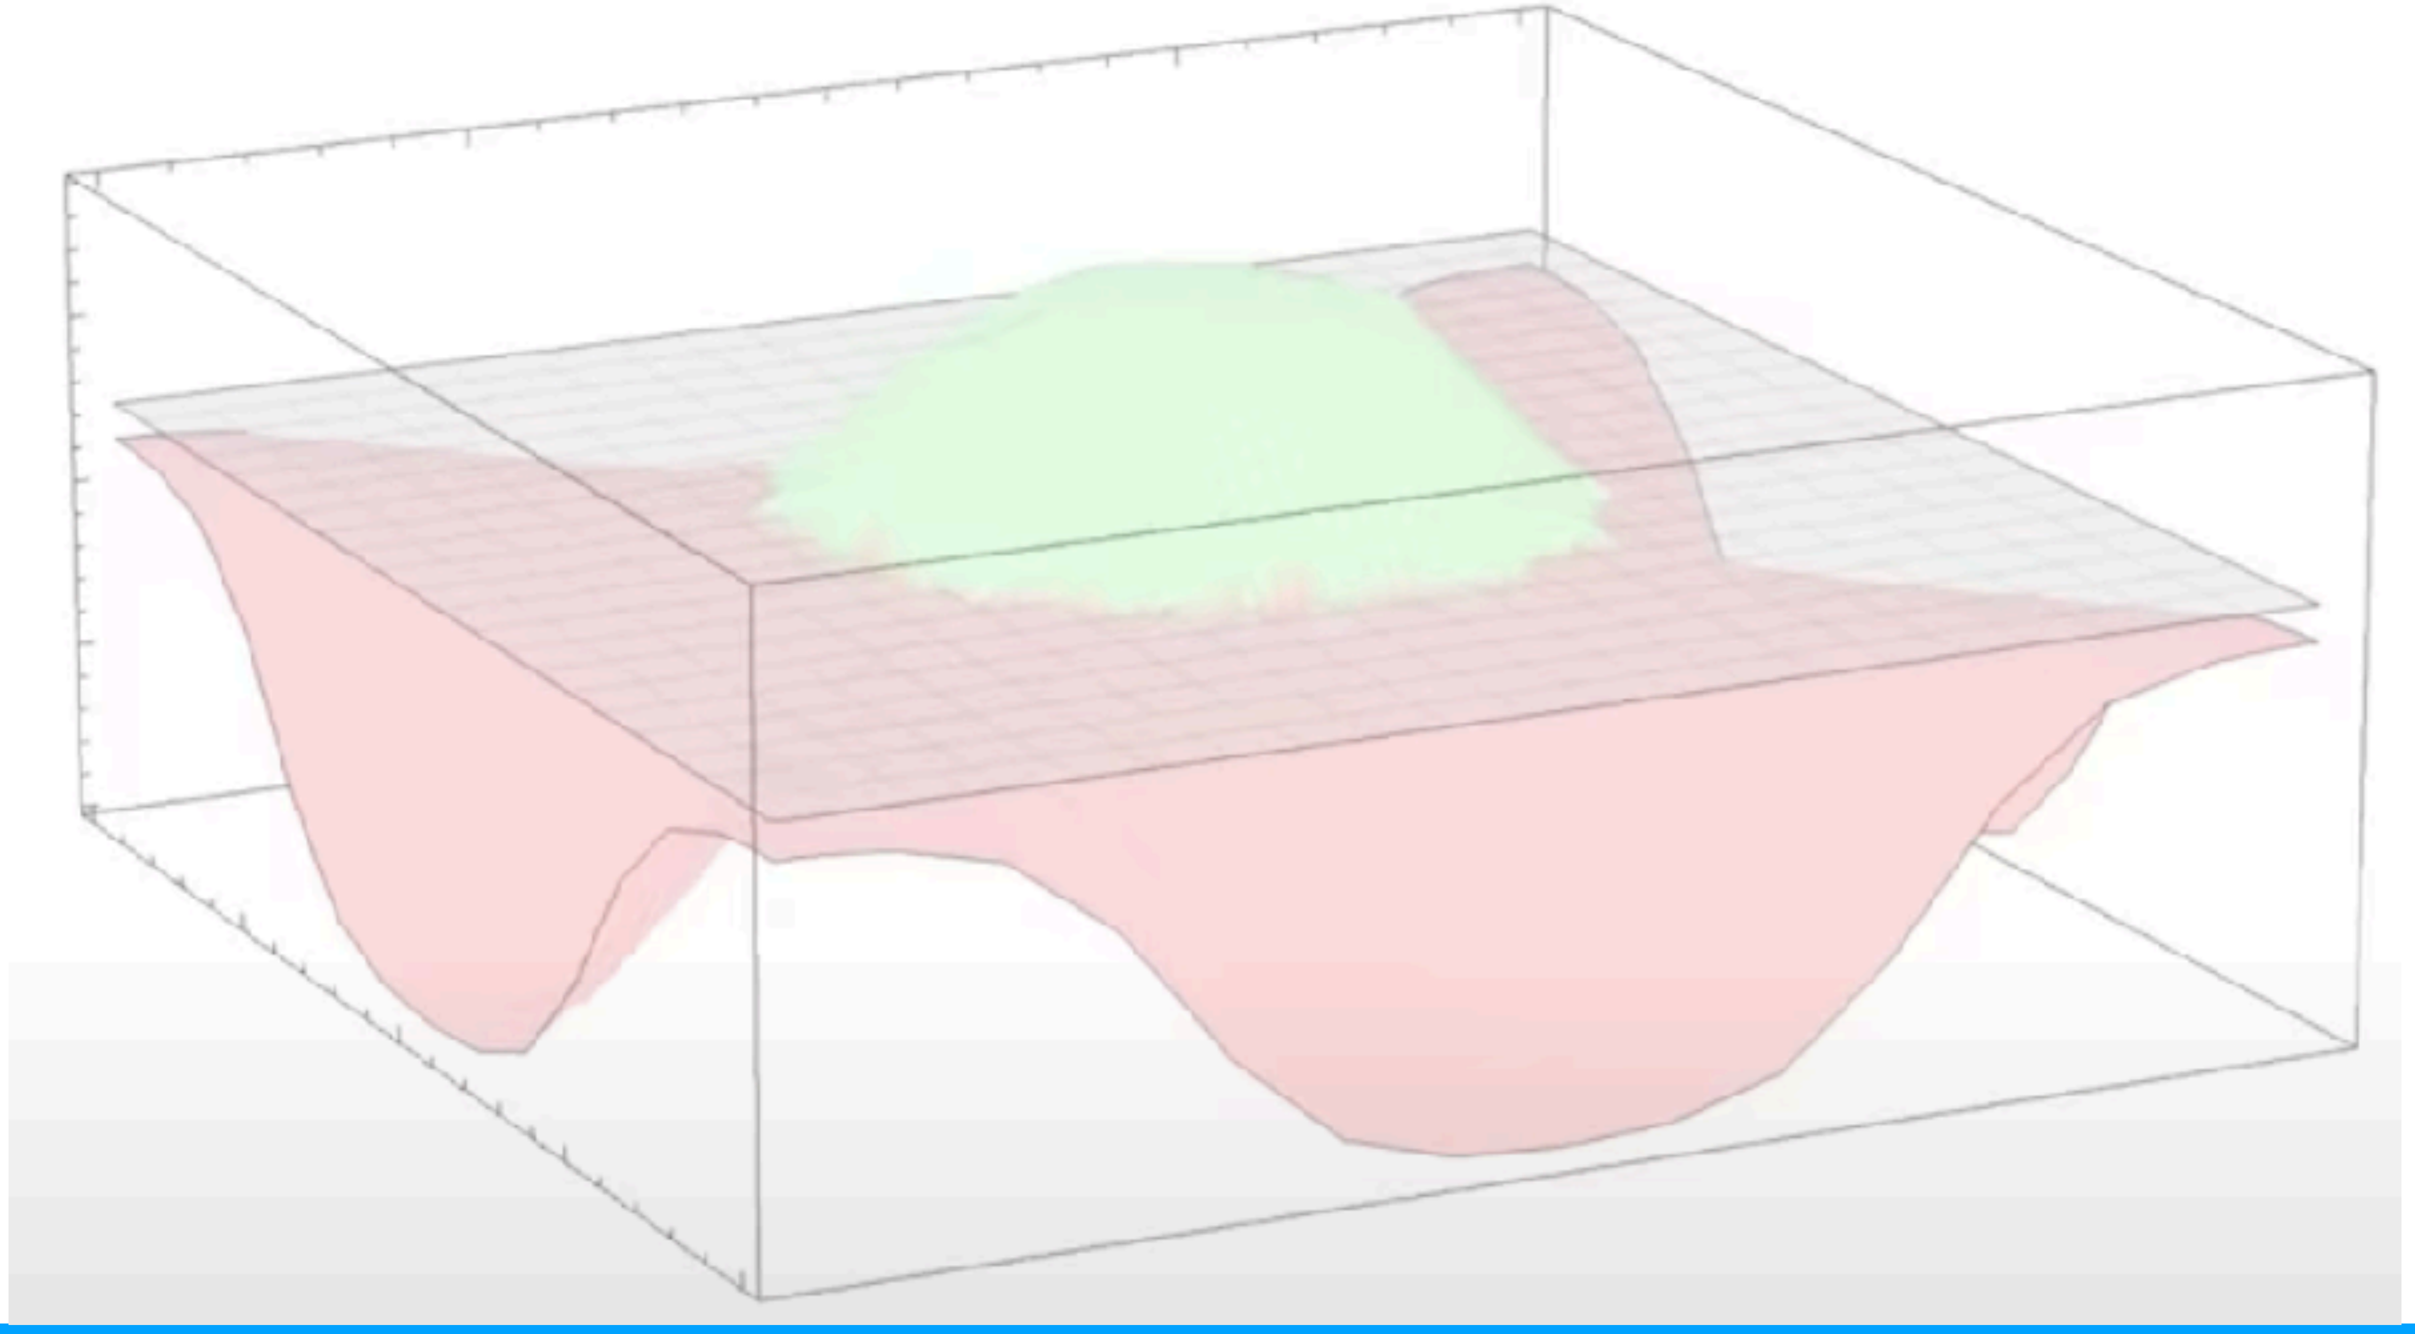

Intro Deep Learning

Backprop - Gradient Descent

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

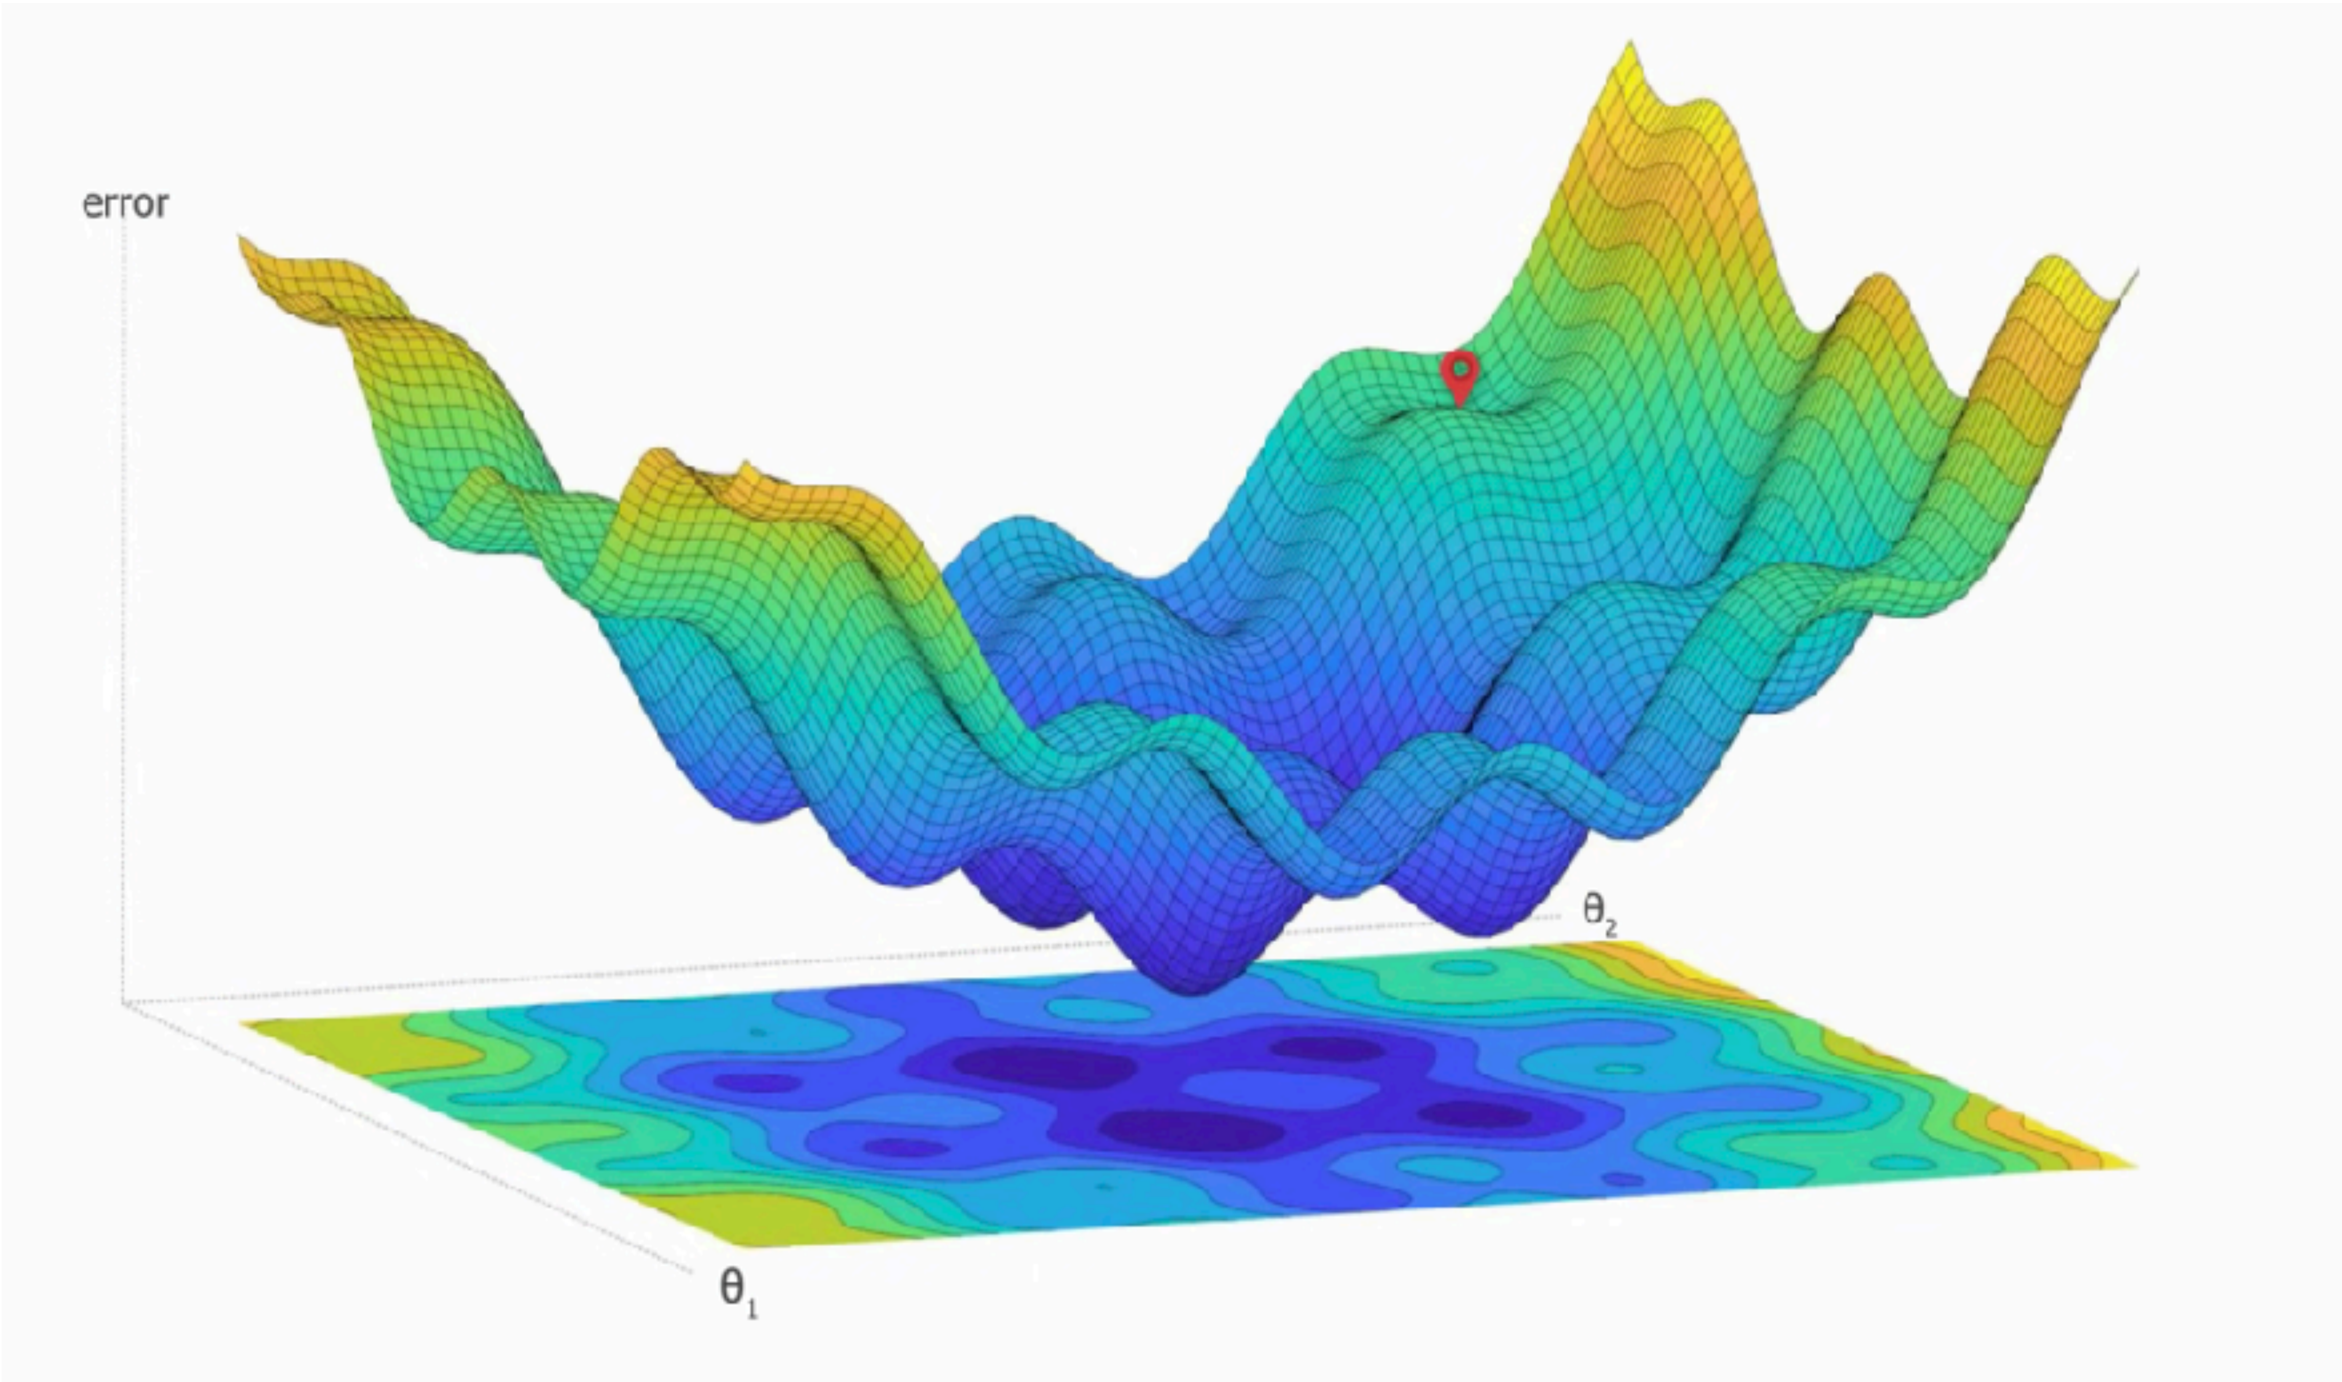

Intro Deep Learning

Backprop - Gradient Descent

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

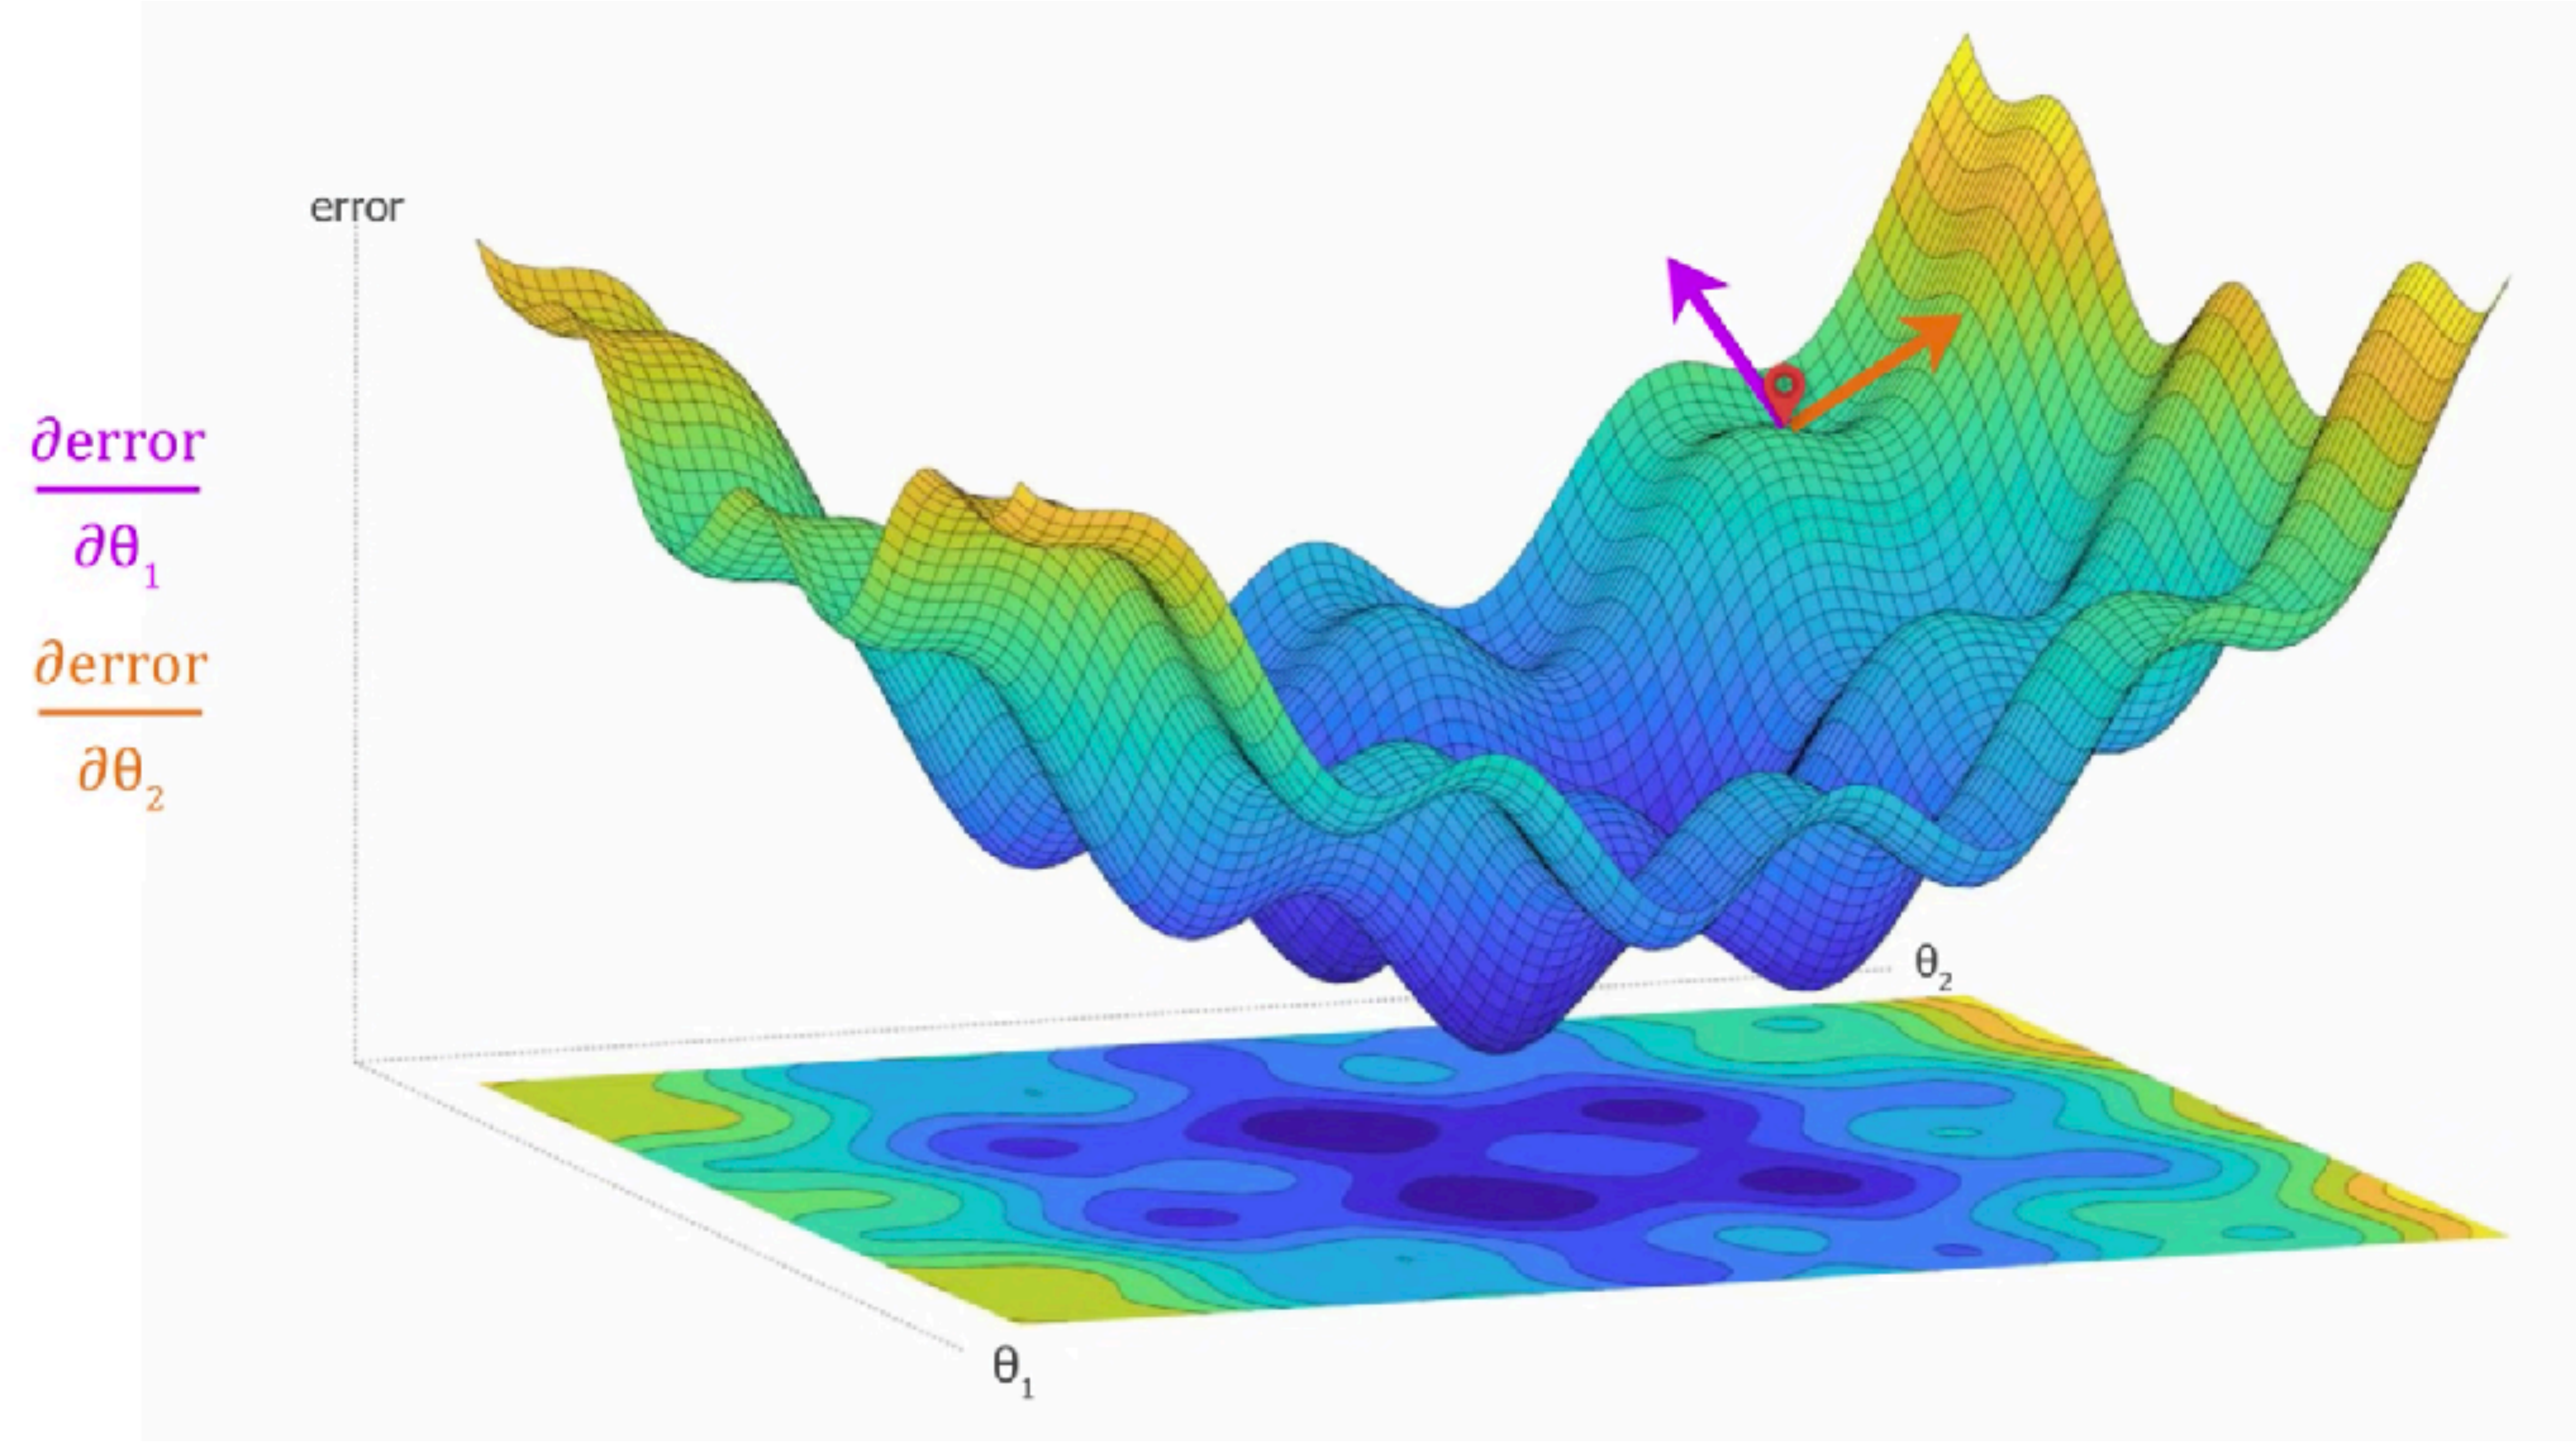

Intro Deep Learning

Backprop - Gradient Descent

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

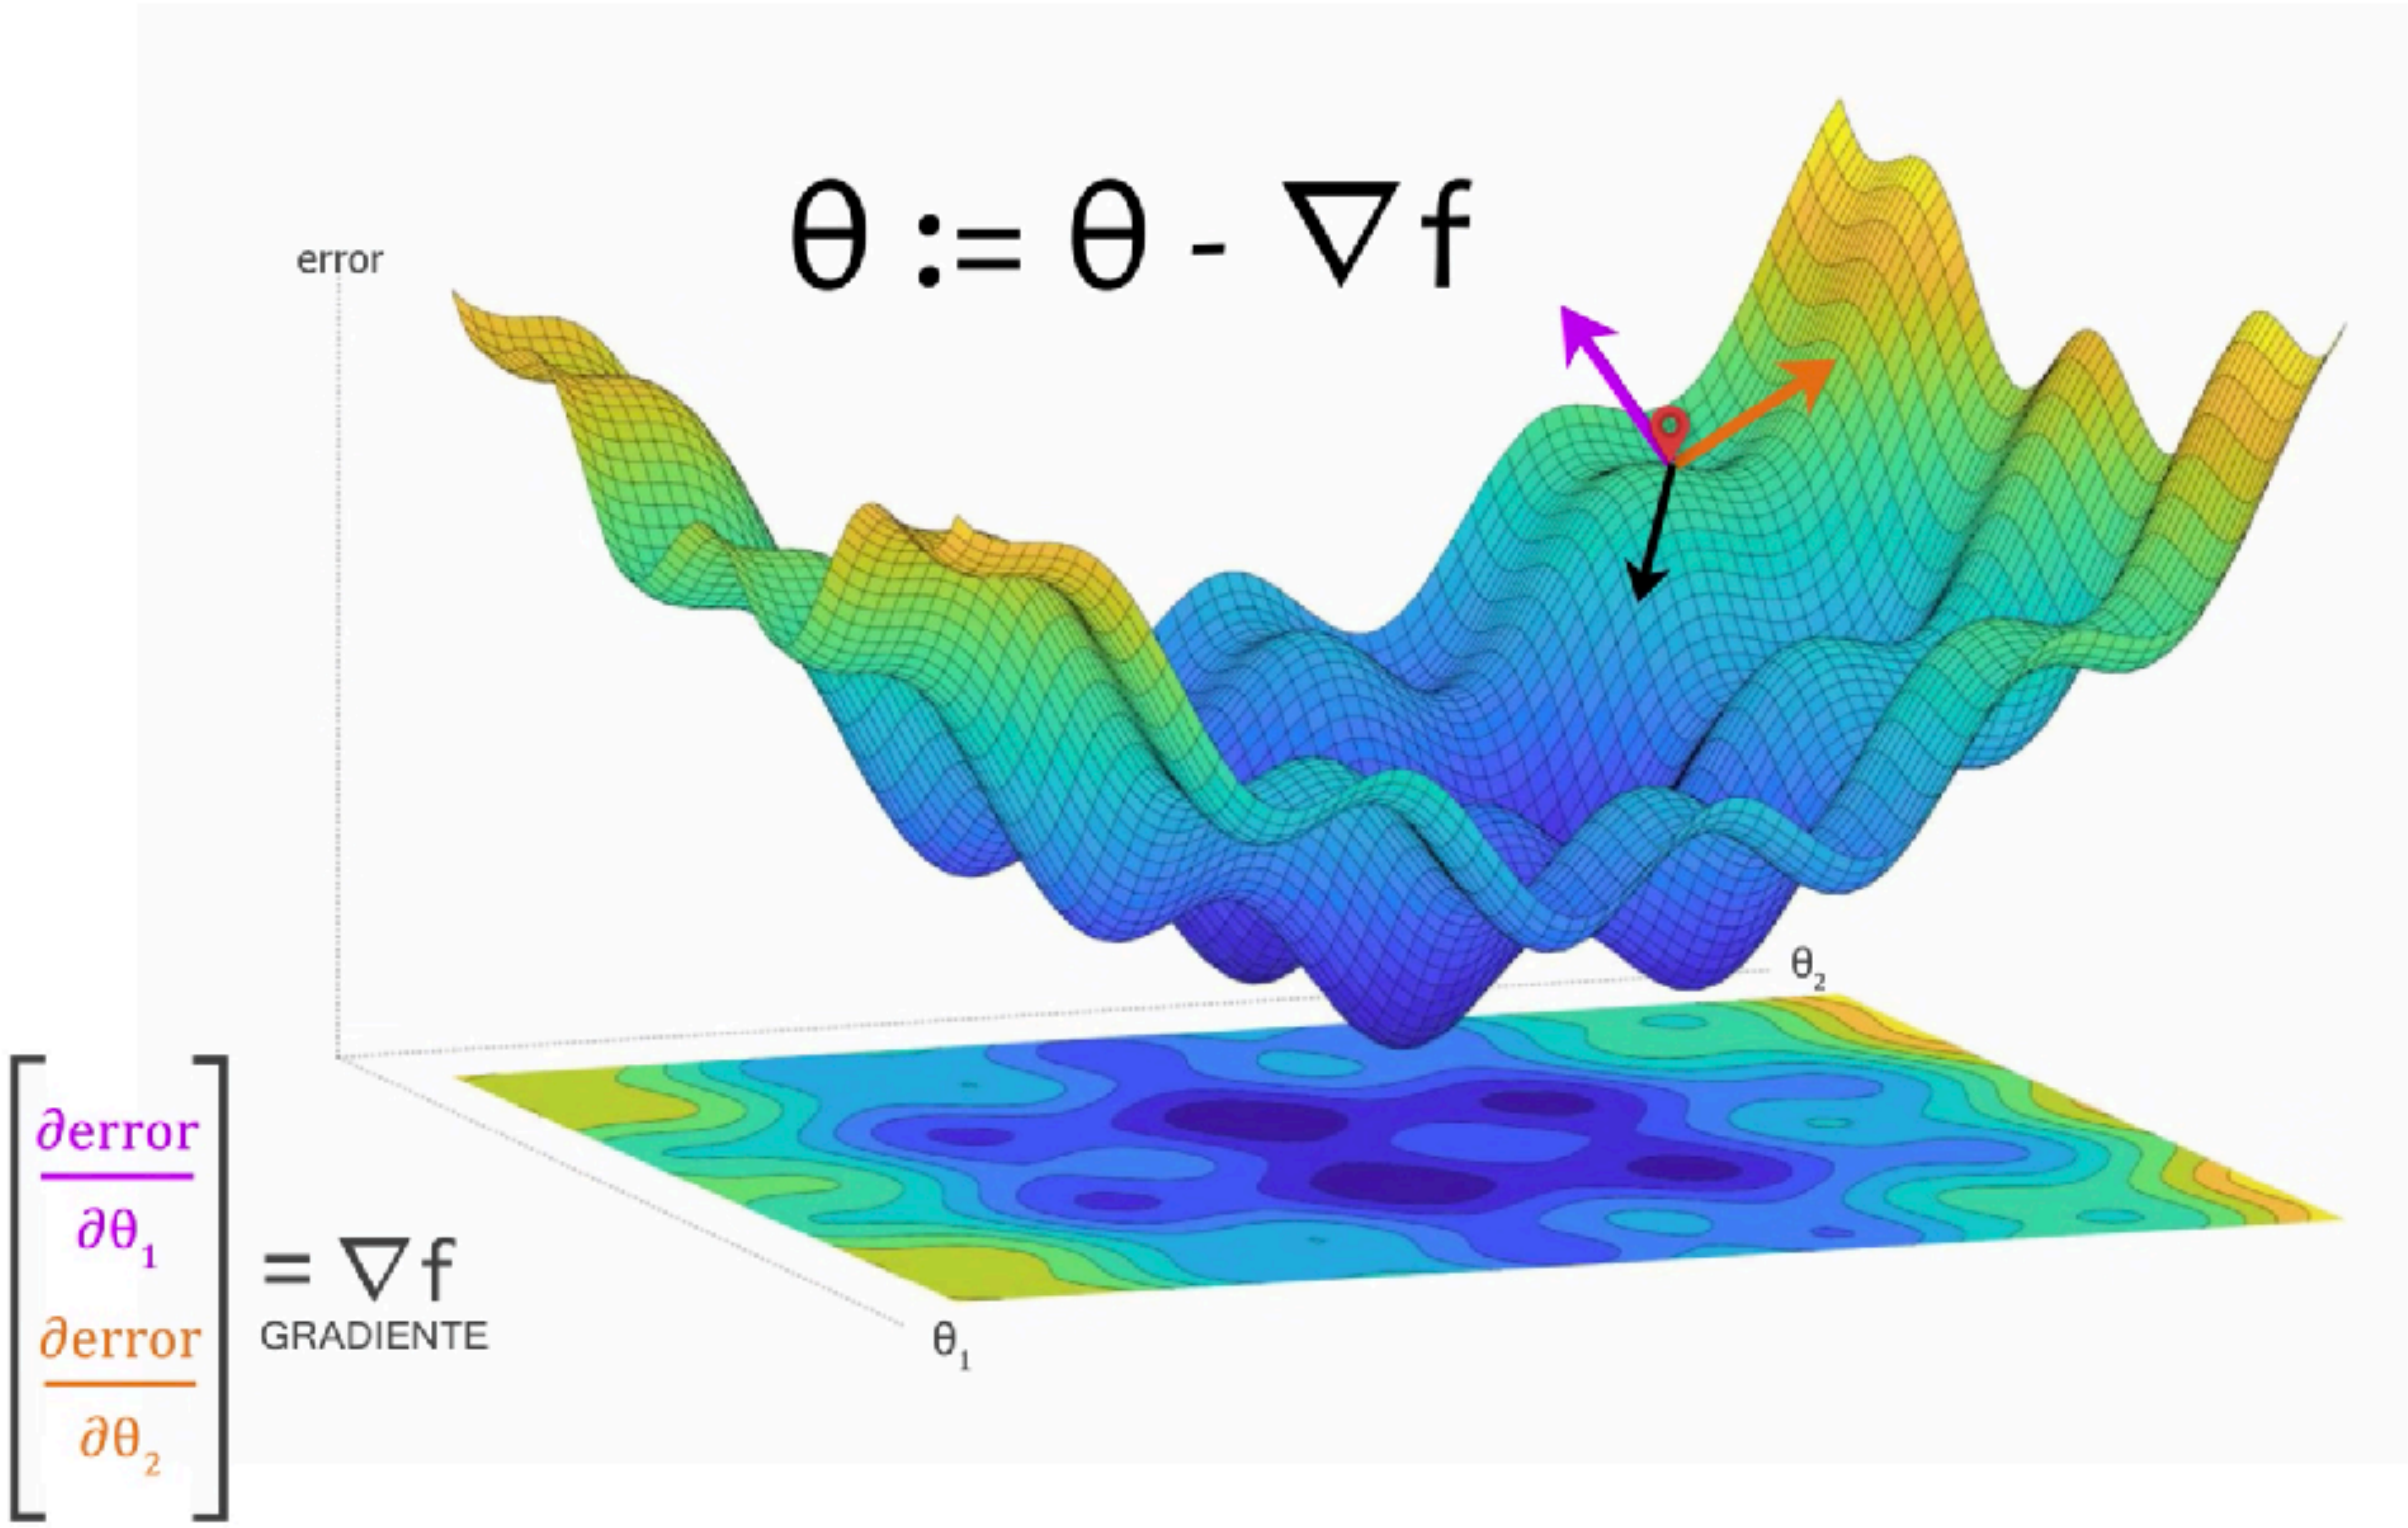

Intro Deep Learning

Backprop - Gradient Descent

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

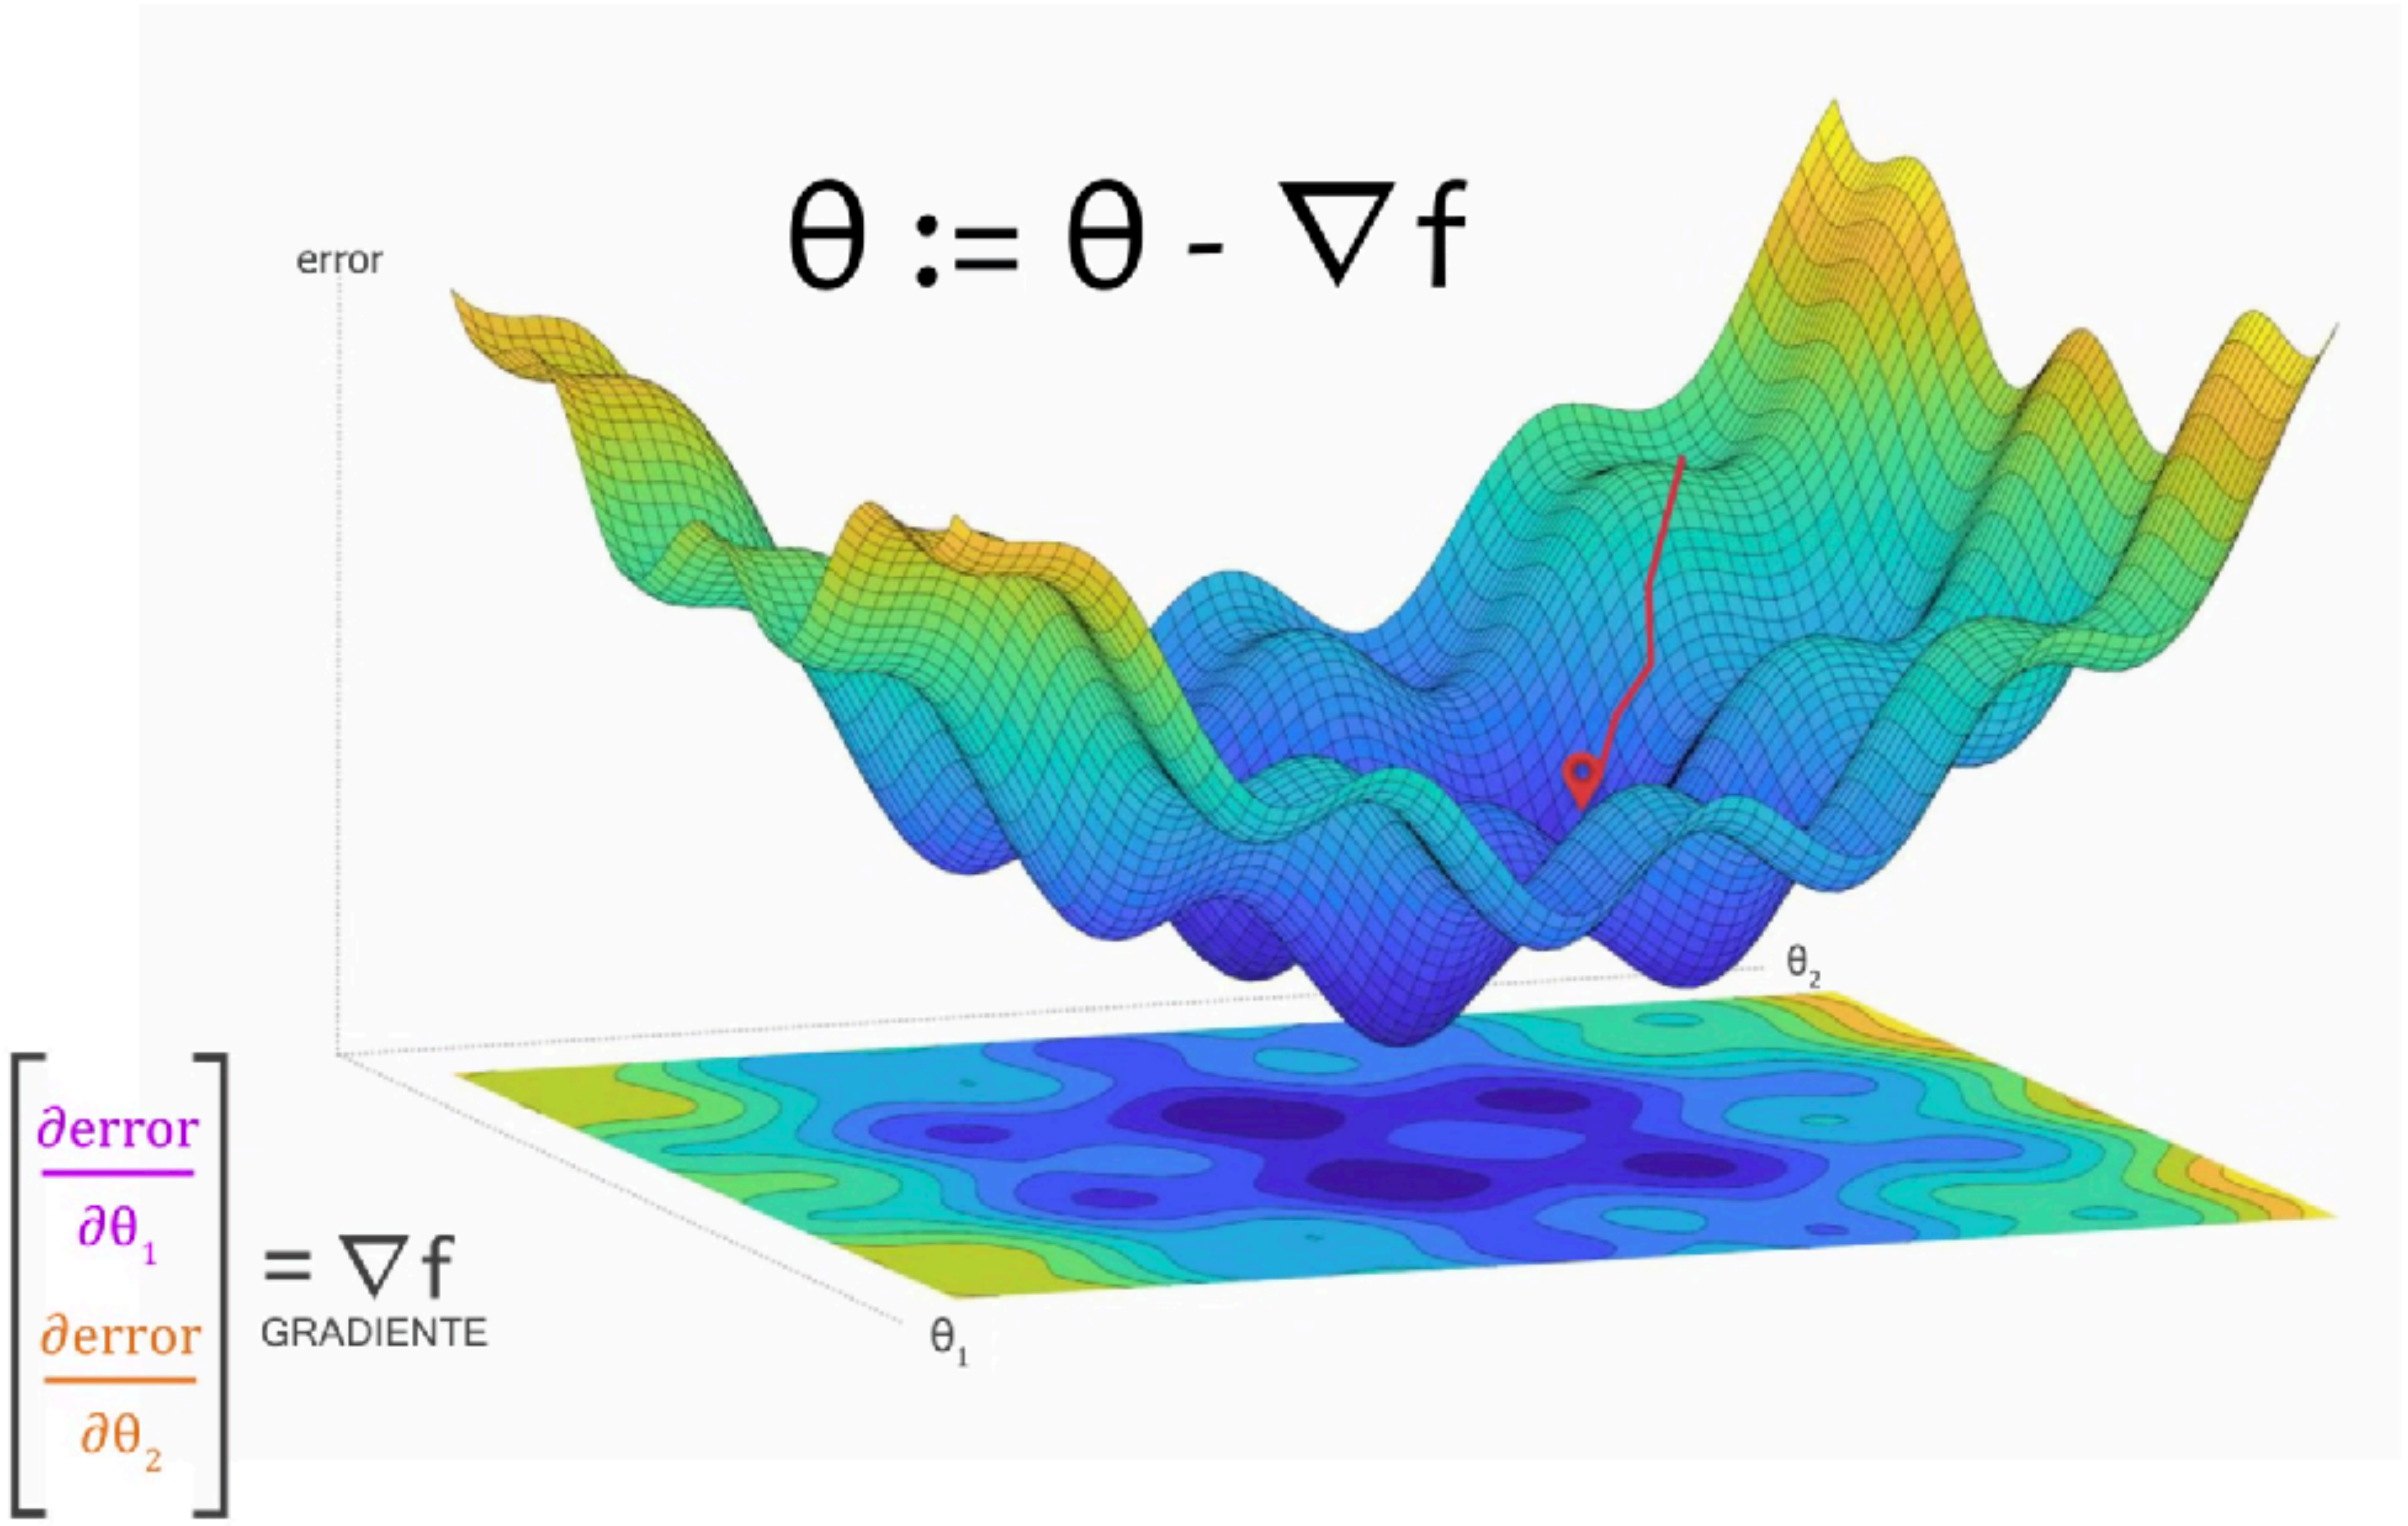

Intro Deep Learning

Backprop - Gradient Descent

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

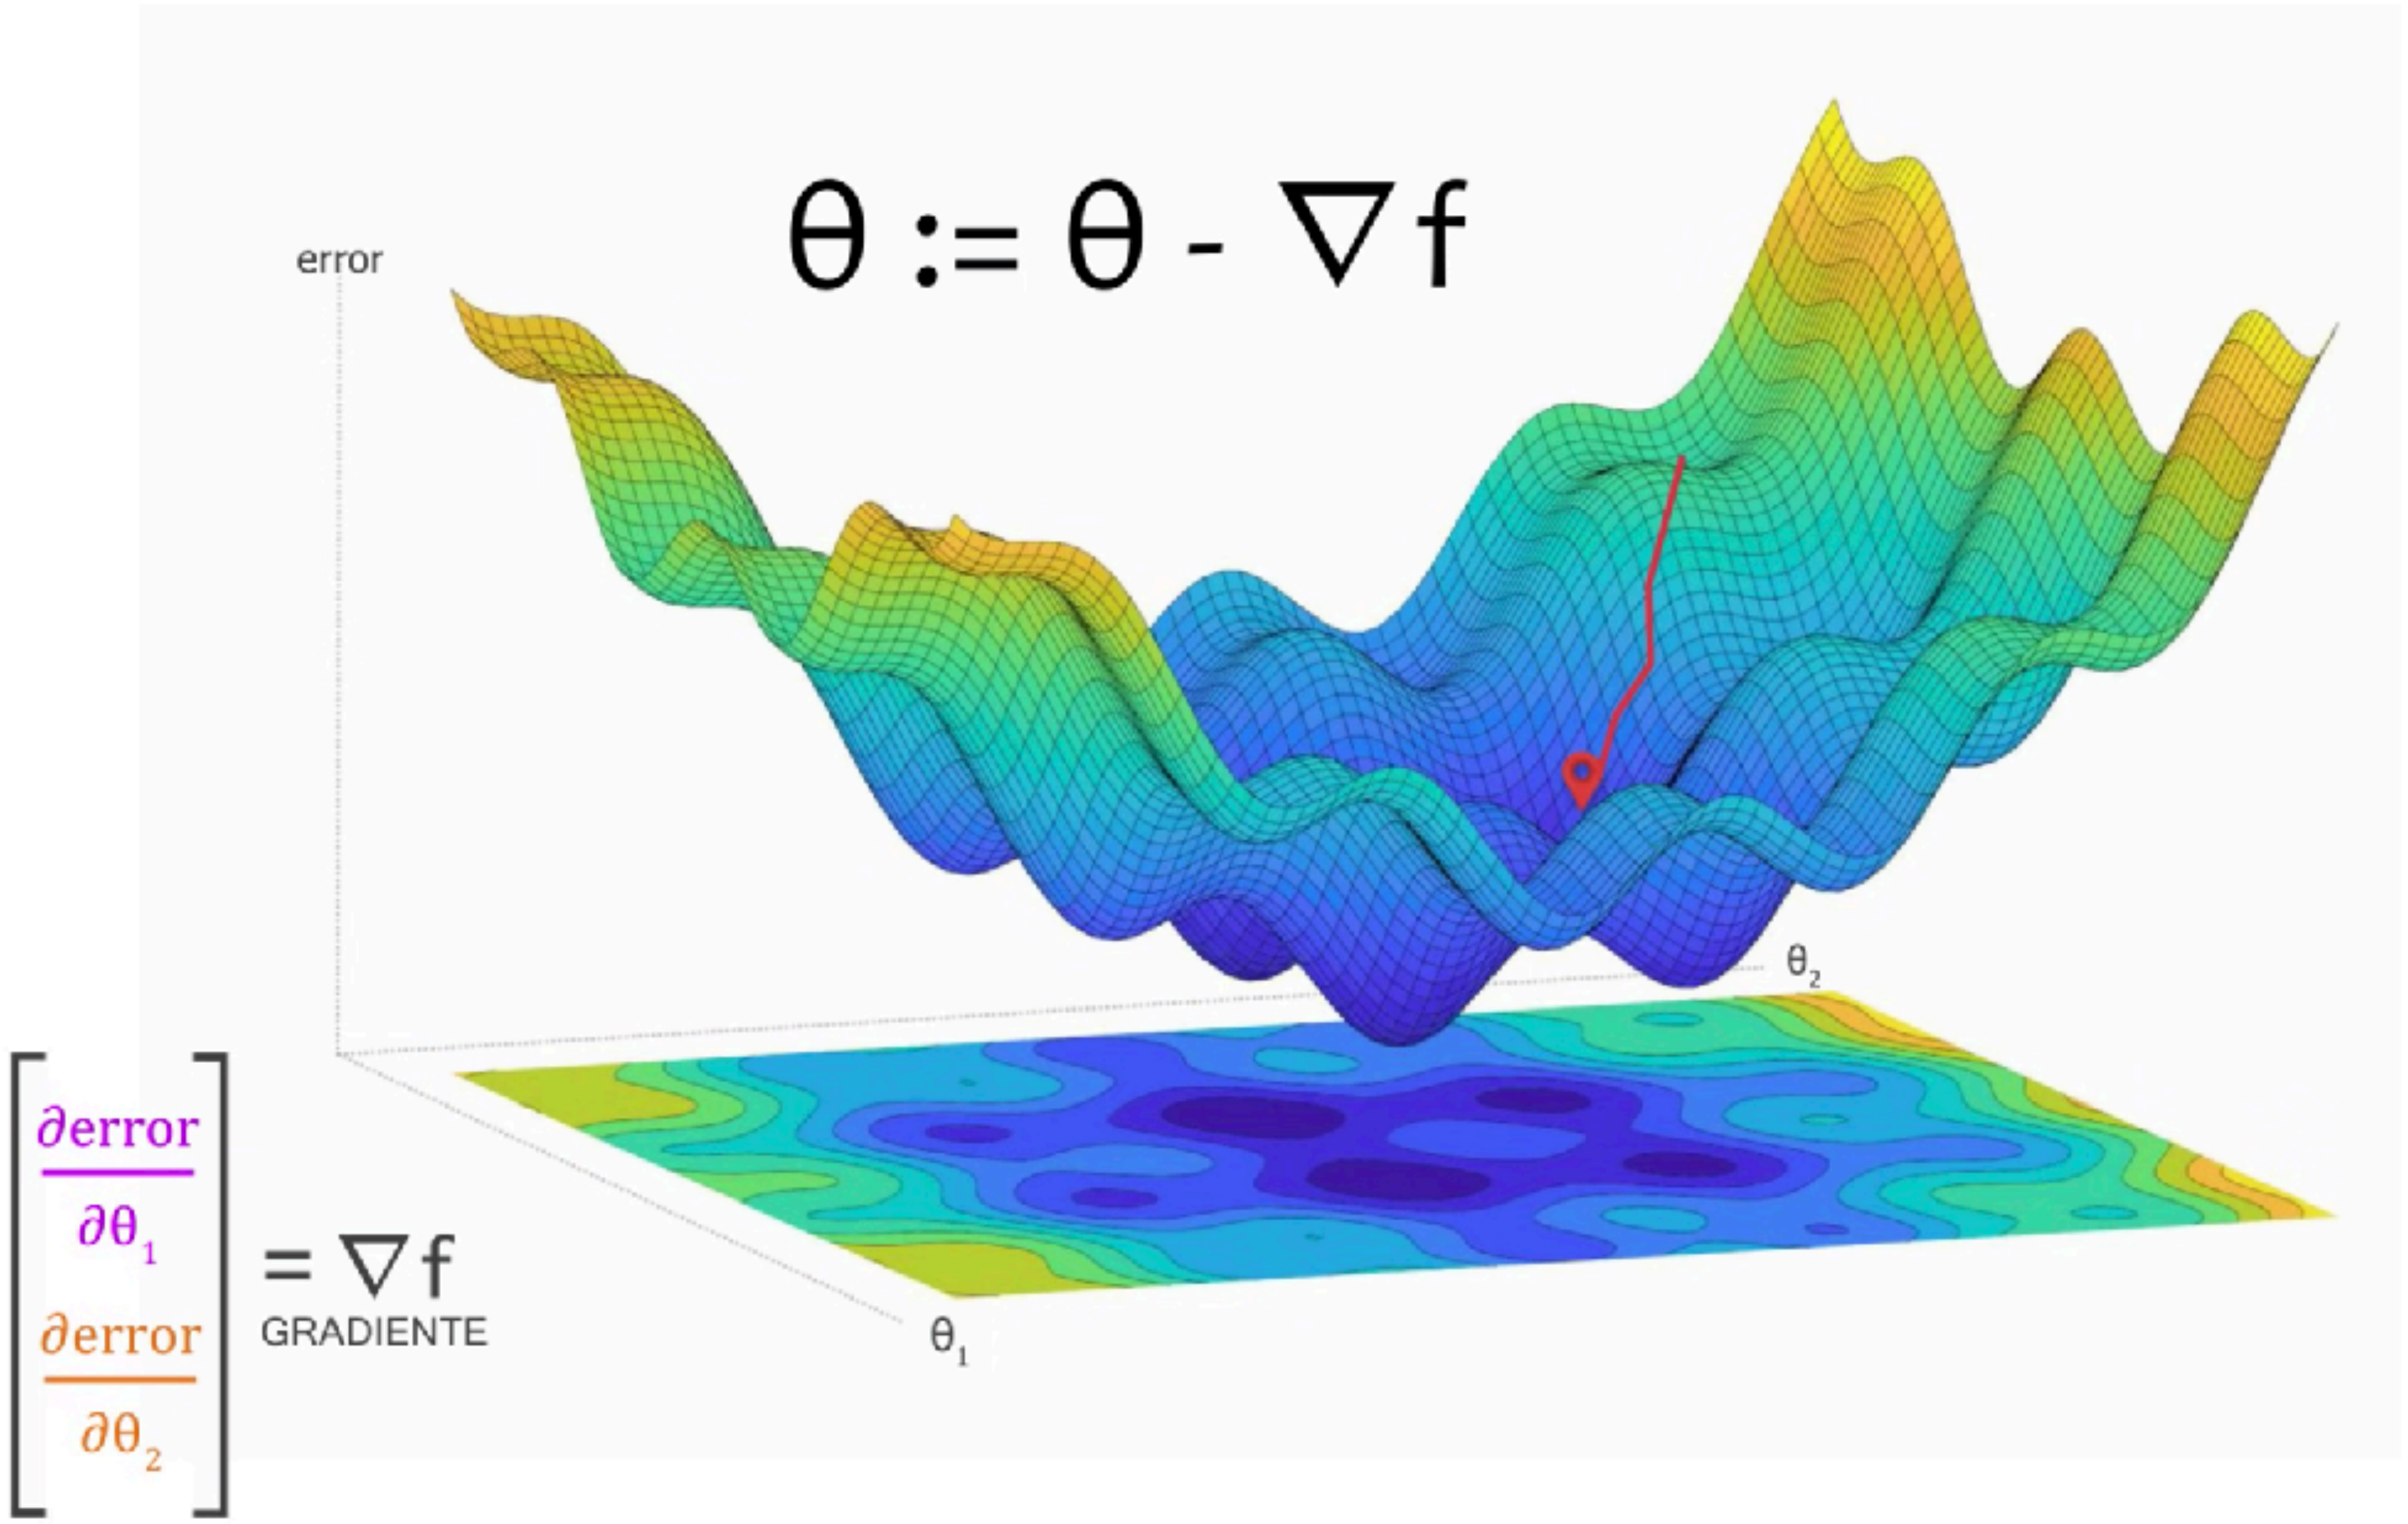

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

En L capas

$$\frac{\partial C}{\partial W^L} \qquad\qquad \frac{\partial C}{\partial b^L}$$

Coste con los pesos W

Coste con los sesgos b

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$Z^L = W^L X + b^L$$ *Suma ponderada*

$$a(Z^L)$$ *Función de activación*

$$C(a(Z^L)) = Error$$ *Función de coste*

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$C(a(Z^L)) = Error$$

Función de coste

Composición de funciones

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

$$\frac{\partial Liebre}{\partial Perro} = 3 \qquad \frac{\partial Perro}{\partial Tortuga} = 5 \qquad \frac{\partial Liebre}{\partial Tortuga} = ??$$

1 minuto para resolver...

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

$$\frac{\partial Liebre}{\partial Perro} = 3 \qquad \frac{\partial Perro}{\partial Tortuga} = 5 \qquad \frac{\partial Liebre}{\partial Tortuga} = 15$$

Se deben multiplicar las derivadas intermedias

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

Se deben multiplicar las derivadas intermedias

$$\frac{\partial Liebre}{\partial Perro} \quad \frac{\partial Perro}{\partial Tortuga} = \frac{\partial Liebre}{\partial Tortuga}$$

Tip: encadenar numerador con denominador…

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

$$\frac{\partial Liebre}{\partial Perro} \quad \frac{\partial Perro}{\partial Tortuga} = \frac{\partial Liebre}{\partial Tortuga}$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

$$\frac{\partial C}{\partial W^L}$$

CHAIN RULE!

$$\frac{\partial C}{\partial b^L}$$

$$Z^L = W^L a^{L-1} + b^L \qquad C(a^L(Z^L))$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

Derivada de composición de funciones se aplica con regla de la cadena o 'Chain Rule'

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial b^L}$$

$$Z^L = W^L a^{L-1} + b^L \qquad C(a^L(Z^L))$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial C}{\partial a_j^L} = (a_j^L - y_j)$$

Derivada de la función de coste

¿Que tanto varía el costo con respecto al output de la última capa?

$$C(a_j^L) = \frac{1}{2}\sum_j (y_j - a_j^L)^2$$

Error cuadrático medio

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial a^L}{\partial Z^L} = a^L(Z^L)\,.\,(1 - a^L(Z^L))$$

Derivada de la función de activación

¿Que tanto varía el output de la neurona cuando variamos la suma ponderada de la neurona?

$$a^L(Z^L) = \frac{1}{1 + e^{-Z^L}}$$

Función sigmoide

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial Z^L}{\partial W^L} = a_i^{L-1} \qquad \frac{\partial Z^L}{\partial b^L} = 1$$

Derivando la suma ponderada

¿Que tanto varía la suma ponderada de la neurona con los parámetros?

$$Z^L = \sum_i a_i^{L-1} . w_i^L + b^L$$

Suma ponderada

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Derivadas de la última capa:

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial b^L}$$

Resumiendo

$$\frac{\partial C}{\partial a_j^L} = (a_j^L - y_j)$$

$$\frac{\partial a^L}{\partial Z^L} = a^L(Z^L)\,.\,(1 - a^L(Z^L))$$

$$\frac{\partial Z^L}{\partial W^L} = a_i^{L-1} \qquad \frac{\partial Z^L}{\partial b^L} = 1$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Error imputado a la neurona

$$\delta^L$$

Derivadas de la última capa:

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial C}{\partial Z^L}$$

Responsabilidad de la neurona en el resultado

Resumiendo

Error a un pequeño cambio en la suma de la neurona.

Derivada grande → *Afecta considerablemente el coste*

Derivada pequeña → *Da igual como se varia la suma, no afectará el coste*

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Error imputado a la neurona

$$\delta^L$$

Derivadas de la última capa:

Resumiendo

$$\frac{\partial C}{\partial W^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial W^L} \longrightarrow \frac{\partial C}{\partial W^L} = \delta^L \cdot \frac{\partial Z^L}{\partial W^L}$$

$$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial z^L} \cdot \frac{\partial Z^L}{\partial b^L} \longrightarrow \frac{\partial C}{\partial b^L} = \delta^L \cdot \frac{\partial Z^L}{\partial b^L}$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Error imputado a la neurona

$$\delta^L$$

Derivadas de la última capa:

Derivando

$$\frac{\partial C}{\partial W^L} = \delta^L \cdot \frac{\partial Z^L}{\partial W^L} \longrightarrow \frac{\partial C}{\partial W^L} = \delta^L \cdot a_i^{L-1}$$

$$\frac{\partial C}{\partial b^L} = \delta^L \cdot \frac{\partial Z^L}{\partial b^L} \longrightarrow \frac{\partial C}{\partial b^L} = \delta^L \cdot 1$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Error imputado a la neurona

$$\delta^L = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L}$$

Derivadas de la última capa:

Derivando

$$\frac{\partial C}{\partial W^L} = \delta^L \cdot a_i^{L-1} \longrightarrow$$

Error de la neurona por la función de activación de la capa anterior.

$$\frac{\partial C}{\partial b^L} = \delta^L \cdot 1 \longrightarrow$$

Derivada del coste con respecto al bias es igual al error de la neurona

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

¿Cómo derivamos la capa anterior?

$$\frac{\partial C}{\partial W^{L-1}}$$

$$\frac{\partial C}{\partial b^{L-1}}$$

CHAIN RULE!

$$C(a^L(W^L \cdot a^{L-1}(W^{L-1} \cdot a^{L-2} + b^{L-1}) + b^L))$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

¿Cómo derivamos la capa anterior?

$$\frac{\partial C}{\partial W^{L-1}} = \frac{\partial C}{\partial a^{L}} \cdot \frac{\partial a^{L}}{\partial Z^{L}} \cdot \frac{\partial Z^{L}}{\partial a^{L-1}} \cdot \frac{a^{L-1}}{\partial Z^{L-1}} \cdot \frac{\partial Z^{L-1}}{\partial W^{L-1}}$$

$$\frac{\partial C}{\partial b^{L-1}} = \frac{\partial C}{\partial a^{L}} \cdot \frac{\partial a^{L}}{\partial Z^{L}} \cdot \frac{\partial Z^{L}}{\partial a^{L-1}} \cdot \frac{a^{L-1}}{\partial Z^{L-1}} \cdot \frac{\partial Z^{L-1}}{\partial b^{L-1}}$$

$$C(a^{L}(W^{L} \cdot a^{L-1}(W^{L-1} \cdot a^{L-2} + b^{L-1}) + b^{L}))$$

Pontificia Universidad JAVERIANA Colombia

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

¿Cómo derivamos la capa anterior?

Derivada de la función de activación

$$\frac{\partial C}{\partial W^{L-1}} = \overset{\delta^L}{\boxed{\frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L}}} \cdot \overset{W^L}{\boxed{\frac{\partial Z^L}{\partial a^{L-1}}}} \cdot \boxed{\frac{a^{L-1}}{\partial Z^{L-1}}} \cdot \overset{a^{L-2}}{\boxed{\frac{\partial Z^{L-1}}{\partial W^{L-1}}}}$$

$$\frac{\partial C}{\partial b^{L-1}} = \boxed{\frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L}} \cdot \boxed{\frac{\partial Z^L}{\partial a^{L-1}}} \cdot \boxed{\frac{a^{L-1}}{\partial Z^{L-1}}} \cdot \overset{1}{\boxed{\frac{\partial Z^{L-1}}{\partial b^{L-1}}}}$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

¿Cómo derivamos la capa anterior?

¿Cómo varia la suma ponderada de una capa cuando se varia el output de una neurona en la capa previa?

$$W^L$$

$$\frac{\partial C}{\partial W^{L-1}} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L} \cdot \boxed{\frac{\partial Z^L}{\partial a^{L-1}}} \cdot \frac{a^{L-1}}{\partial Z^{L-1}} \cdot \frac{\partial Z^{L-1}}{\partial W^{L-1}}$$

$$\frac{\partial C}{\partial b^{L-1}} = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L} \cdot \boxed{\frac{\partial Z^L}{\partial a^{L-1}}} \cdot \frac{a^{L-1}}{\partial Z^{L-1}} \cdot \frac{\partial Z^{L-1}}{\partial b^{L-1}}$$

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Resumiendo back-propagation

1. Computo del error de la última capa

$$\delta^L = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L}$$

2. Retropropagamos el error a la capa anterior

$$\delta^{L-1} = W^L \cdot \delta^L \cdot \frac{\partial a^{L-1}}{\partial Z^{L-1}}$$

3. Calculamos las derivadas de la capa usando el error

$$\frac{\partial C}{\partial b^{L-1}} = \delta^{L-1} \qquad \frac{\partial C}{\partial W^{L-1}} = \delta^{L-1} \cdot a^{L-2}$$

¡Backprop es derivar solo 4 expresiones!

Intro Deep Learning

Backprop

Perceptrón Multicapa (MLP)

Las limitaciones de los perceptrones se pueden eliminar apilando varios perceptrones

Resumiendo back-propagation

¡Backprop es derivar solo 4 expresiones!

1. Computo del error de la última capa

$$\delta^L = \frac{\partial C}{\partial a^L} \cdot \frac{\partial a^L}{\partial Z^L}$$

2. Retropropagamos el error a la capa anterior

$$\delta^{L-1} = W^L \cdot \delta^L \cdot \frac{\partial a^{L-1}}{\partial Z^{L-1}}$$

3. Calculamos las derivadas de la capa usando el err

$$\frac{\partial C}{\partial b^{L-1}} = \delta^{L-1} \qquad \frac{\partial C}{\partial W^{L-1}} = \delta^{L-1} \cdot a$$